Diplomado en Ciencia de Datos y Análisis Avanzado

UTN.BA · Unidad 10 · Proyecto Final Integrador

Informe Final

Priorización de acciones de retención: predicción de abandono (churn) de clientes en una empresa de telecomunicaciones

Grupo 4

Integrantes

Agustín Bilche Braga

Agustina Díaz

Carlos Grozo

Milagros Crespo

Luana Zalcman

Octubre de 2026

Índice

1. Resumen ejecutivo - 2. Definición del problema y relevancia - 3. Datos y metodología - 4. Modelado y evaluación - 5. Interpretación del modelo - 6. Impacto en el negocio, riesgos y ética - 7. Conclusiones y recomendaciones - Anexos

1. Resumen ejecutivo

Problema. Una empresa de telecomunicaciones pierde a cerca de 1 de cada 4 clientes de su cartera: la **tasa de churn observada en la muestra** es 26,5 %. El área de Retención puede contactar aproximadamente al 20 % de la cartera por campaña y hoy no tiene un criterio para elegir a quién. **Público:** el área de Retención y Marketing (usuaria del ranking) y la dirección comercial (decide el presupuesto de las campañas).

Solución. Un modelo de Regresión Logística que ordena a los clientes por riesgo estimado de abandono, para que el cupo de contactos se use primero con quienes tienen mayor score. Se compararon cinco variantes (incluidos Random Forest y Gradient Boosting) y quedaron estadísticamente empatadas; una regla definida antes de mirar el test elige la más simple e interpretable.

Indicador (test interno, 1.127 clientes)	Contacto al azar	Modelo
Abandonos detectados contactando al 20 % de mayor riesgo	20,1 %	**53,2 %**
Precisión dentro del 20 % contactado	26,6 %	70,4 %
PR-AUC (piso = tasa de churn 0,265)	0,270	0,666 (×2,5)
Valor neto preservado por 10.000 clientes (USD 100 por cliente retenido)*	USD 276.469	USD 823.584

Tabla 1. Resultados principales. *Escenario paramétrico con supuestos explícitos (sección 6), no costos reales de la empresa.

Resultado (KPI de negocio). Contactando al 20 % mejor rankeado se detecta el **53,2 %** de los clientes que realmente abandonan, 2,65 veces más que al azar (IC 95 %: 49,2 % a 57,9 %). Con una tasa de 26,5 %, contactar al 20 % permite detectar como máximo el 75 %. La meta definida antes de entrenar era 55 % (mínimo aceptable 50 %): **se cumple el mínimo pero no la meta**.

Qué explica el riesgo. La antigüedad es la variable más influyente (los primeros seis meses concentran el abandono), seguida por el contrato mes a mes, la fibra óptica y la falta de servicios de soporte.

Recomendación. Usar el ranking como herramienta de priorización con intervención humana y validarlo con un **piloto A/B** (20 % priorizado por el modelo contra 20 % al azar) antes de escalarlo, midiendo la tasa real de retención. Conviene priorizar a los clientes que se van y además gastan mucho, siempre que retenerlos cueste menos que su valor.

2. Definición del problema y relevancia

La pregunta de negocio no es "quién se va a ir con certeza", sino **a quién contactar primero** con un cupo limitado de llamadas e incentivos. Por eso el producto es un ranking de riesgo y no solo una clasificación sí/no. Retener a un cliente suele costar menos que adquirir uno nuevo, y cada contacto a un cliente que no iba a irse es capacidad perdida.

KPI de negocio: porcentaje de los clientes que abandonan que quedan dentro del 20 % contactado (Recall @ 20 %). **KPI de impacto:** valor neto preservado por la campaña (valor de los clientes retenidos menos el costo de retenerlos) frente a contactar al azar (sección 6). **Objetivo medible (definido antes de correr los modelos de esta entrega):** detectar ≥ 55 % de los abandonos contactando al 20 % de la cartera (mínimo aceptable 50 %). **Benchmark:** un orden aleatorio detecta ~20 %. **Techo:** 0,20 / 0,265 ≈ 75 %.

Situación	Lectura estadística	Costo de negocio
Cliente contactado que no iba a irse	Falso positivo dentro del cupo	Consume un contacto y, si hay incentivo, un descuento innecesario.
Cliente que se va y quedó fuera del 20 %	Falso negativo operativo	Se pierde su facturación futura.
Predecir siempre "no abandona"	Accuracy ≈ 73,5 %	Parece aceptable, pero no prioriza a nadie.

Tabla 2. Costo de cada tipo de error.

Hipótesis (de la pre-entrega):

- **H1:** el contrato mes a mes concentra más abandono que los contratos de 1 o 2 años.
- **H2:** a menor antigüedad, mayor abandono.
- **H3:** no tener TechSupport u OnlineSecurity y pagar con Electronic check se asocian a más abandono.
- **H4:** cargos mensuales más altos se asocian a más abandono.

3. Datos y metodología

Fuente. Competencia de Kaggle *Predicción de fuga de cliente* (kaggle.com/competitions/prediccion-de-fuga-de-cliente), basada en el dataset Telco Customer Churn. **train.csv**: 5.634 clientes y 21 columnas (perfil, servicios contratados, contrato, facturación y *Churn*). **test.csv**: 1.409 clientes sin *Churn*, usados solo para generar predicciones. El dataset es una foto estática: no tiene fechas, por lo que no se puede hablar de una tasa mensual ni hacer validación temporal. Son datos públicos de uso académico y anonimizados: el cliente se identifica solo por un código (*customerID*), sin nombres ni datos de contacto. **Variables clave:** *tenure* (antigüedad en meses), *Contract* (mes a mes, 1 o 2 años), *InternetService*, *TechSupport*, *OnlineSecurity*,

PaymentMethod, *MonthlyCharges* y *TotalCharges*; el diccionario completo está en *data/README.md*.

Hallazgo de calidad	Decisión y motivo
0 nulos explícitos, pero los 8 clientes con *tenure* = 0 traen *TotalCharges* = 1.397,475 (la mediana)	**Corregido a 0**: el archivo venía pre-imputado. Un cliente sin meses facturados no acumuló cargos. La pre-entrega había reportado "sin nulos".
15 filas idénticas salvo el *customerID*	Se conservan: son clientes distintos con el mismo perfil.
TotalCharges ≈ *tenure* × *MonthlyCharges* (mediana del cociente 1,00)	Se descarta el "cargo promedio por mes" pendiente de la pre-entrega: repetiría *MonthlyCharges*.
Servicios adicionales dispersos en 6 columnas	Se agrega *n_servicios* (0-6) como resumen del "enganche" del cliente.
Desbalance: 26,5 % abandona	Métricas de ranking (Recall @ 20 %, PR-AUC); accuracy solo como referencia.

Tabla 3. Calidad de datos y decisiones (detalle en data_log.md).

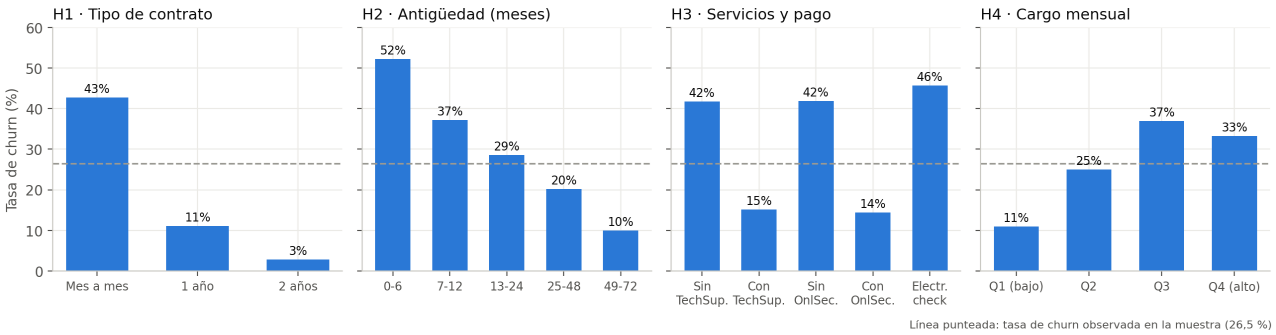


Figura 1. Tasa de churn por contrato (H1), antigüedad (H2), servicios y forma de pago (H3) y cuartil de cargo mensual (H4). Línea punteada: tasa observada en la muestra.

Conclusiones del EDA.

- **H1:** el contrato mes a mes abandona 42,7 %, contra 11,1 % (1 año) y 2,9 % (2 años).
- **H2:** el abandono es 52,2 % en los primeros seis meses y baja de forma monótona hasta 9,9 % después de los cuatro años.
- **H3:** sin TechSupport u OnlineSecurity la tasa ronda 42 %, contra 14-15 % con el servicio; Electronic check llega a 45,7 %.
- **H4:** el abandono crece del cuartil más bajo (10,9 %) al tercero (37,0 %), pero baja levemente en el más alto (33,3 %).
- Contrato, antigüedad y cargos están relacionados entre sí: el EDA es descriptivo y el aporte propio de cada grupo de variables se mide quitándolas del modelo (sección 5).

Metodología. Se siguió CRISP-DM: negocio (sección 2), comprensión y preparación de datos (sección 3), modelado y evaluación (sección 4) y traducción a una decisión (secciones 5-6). Todo el preprocesamiento (One-Hot para categóricas, escalado para numéricas) vive dentro de un *Pipeline* que se ajusta solo con datos de entrenamiento, con *random_state* = 42 y las decisiones registradas en *data_log.md*.

Diseño de validación. Validación cruzada estratificada de 5 folds sobre el 80 % de desarrollo para elegir el modelo; un test estratificado del 20 % (la misma partición de la pre-entrega) usado una sola vez para medir el desempeño con clientes no vistos; intervalos de confianza del 95 % (remuestreando el test 2.000 veces) para saber si las diferencias entre modelos superan el ruido; y las predicciones de la validación cruzada del desarrollo para elegir el umbral sí/no y repetir la auditoría ética sin tocar el test. No hay validación temporal porque los datos no tienen fechas.

4. Modelado y evaluación

Siguiendo la devolución de la pre-entrega, el baseline se comparó con Random Forest y Gradient Boosting. Cada variante responde una pregunta concreta: la logística **balanceada** es el baseline de la pre-entrega; la **sin ponderar** mide si la ponderación cambia el ranking o solo el umbral; la variante con **SMOTE** mide si sobremuestrear ayuda (SMOTE vive dentro de un *imblearn.Pipeline*, así que solo se aplica sobre los datos de entrenamiento de cada fold); Random Forest (500 árboles, hoja mínima 5) y Gradient Boosting (300 árboles, profundidad 3) miden si un modelo no lineal captura algo más.

Regla de selección definida antes de ver el test: los modelos a menos de un desvío estándar de la mejor PR-AUC media en CV se consideran empatados; entre empatados se elige el más simple (logística sin ponderar → balanceada → SMOTE → Random Forest → Gradient Boosting).

Modelo	PR-AUC CV (media ± desvío)	ROC-AUC CV	Recall @ 20 % CV
Logística sin ponderar	**0,659 ± 0,023**	**0,844**	**50,4 %**
Logística + SMOTE (solo train)	0,659 ± 0,024	0,844	49,8 %
Logística balanceada (pre-entrega)	0,657 ± 0,024	0,843	50,1 %
Random Forest	0,657 ± 0,031	0,843	50,1 %
Gradient Boosting	0,653 ± 0,043	0,839	48,6 %

Tabla 4. Validación cruzada de 5 folds sobre 4.507 clientes. Umbral de empate: 0,636. Los cinco modelos quedan empatados.

Los cinco modelos quedan dentro del margen de empate (PR-AUC entre 0,653 y 0,659, con desvíos de 0,02 a 0,04). La regla elige la **Regresión Logística sin ponderar**. Dos lecturas: la ponderación de clases y SMOTE no cambian el ranking (solo mueven el umbral), y los árboles no encuentran interacciones que la logística no capture.

Modelo (test)	PR-AUC	ROC-AUC	Recall @ 20 %	Precisión @ 20 %
Ranking aleatorio	0,270	0,500	20,1 %	26,6 %
Logística sin ponderar	**0,666**	**0,848**	**53,2 %**	**70,4 %**
Logística + SMOTE (solo train)	0,667	0,849	53,5 %	70,8 %
Logística balanceada (pre-entrega)	0,666	0,848	53,2 %	70,4 %
Random Forest	0,655	0,847	51,5 %	68,1 %
Gradient Boosting	0,673	0,853	52,8 %	69,9 %

Tabla 5. Evaluación única sobre el 20 % de test (1.127 clientes, 299 abandonos).

En el test, Gradient Boosting obtiene la PR-AUC más alta (0,673 contra 0,666), pero la diferencia no es significativa: el intervalo de confianza del 95 % de la diferencia va de -0,034 a +0,018, y en Recall @ 20 % de -2,3 a +3,6 puntos. Coincide con la CV: no hay un ganador claro, y la regla definida de antemano no se cambia por el resultado del test.

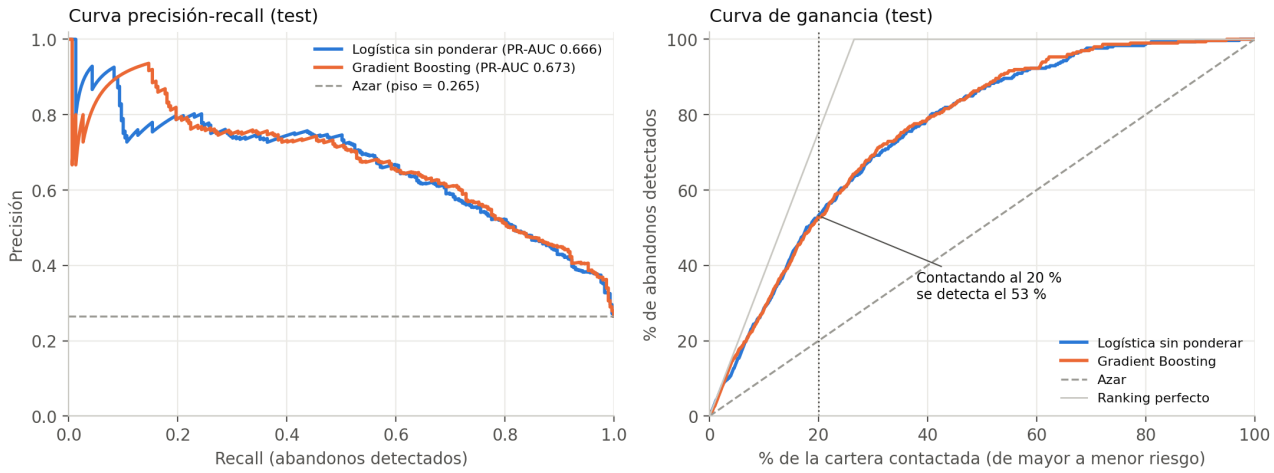


Figura 2. Curva precisión-recall y curva de ganancia en el test. Línea vertical punteada: cupo de 20 %. Las curvas de la logística y de Gradient Boosting prácticamente se superponen.

% de la cartera contactada	Abandonos detectados	Precisión	Veces mejor que el azar
10 %	28,8 %	76,1 %	2,87
20 %	**53,2 %**	**70,4 %**	**2,65**
30 %	68,9 %	60,8 %	2,29
40 %	78,9 %	52,3 %	1,97
50 %	87,0 %	46,1 %	1,74

Tabla 6. Abandonos detectados según el porcentaje de la cartera contactada (modelo elegido, test).

Probabilidades y umbral. La ponderación de clases y SMOTE inflan las probabilidades: la logística balanceada de la pre-entrega le asigna al cliente promedio un riesgo bastante mayor que el real, porque entrena como si la mitad de los clientes abandonara. La logística sin ponderar da probabilidades cercanas a las tasas reales (gráfico en results/ del repositorio), así que su score puede leerse como una probabilidad aproximada. Si se necesita una etiqueta sí/no (por ejemplo, para la competencia), el umbral se eligió maximizando F1 con las predicciones de la validación cruzada, sin mirar el test: 0,328. Con él, en el test se detecta el 72,6 % de los abandonos con precisión 56,7 % (F1 0,636), marcando como riesgo al 34,0 % de los clientes.

5. Interpretación del modelo

Se usó SHAP (*LinearExplainer*) sobre los 1.127 clientes del test. Las columnas One-Hot se sumaron por variable original, así el negocio lee "Contract" y no tres columnas. SHAP asigna a cada variable una contribución al riesgo de cada cliente: el signo indica si la variable sube o baja el riesgo y la magnitud cuánto lo mueve. **SHAP describe cómo razona el modelo; no demuestra causalidad.**

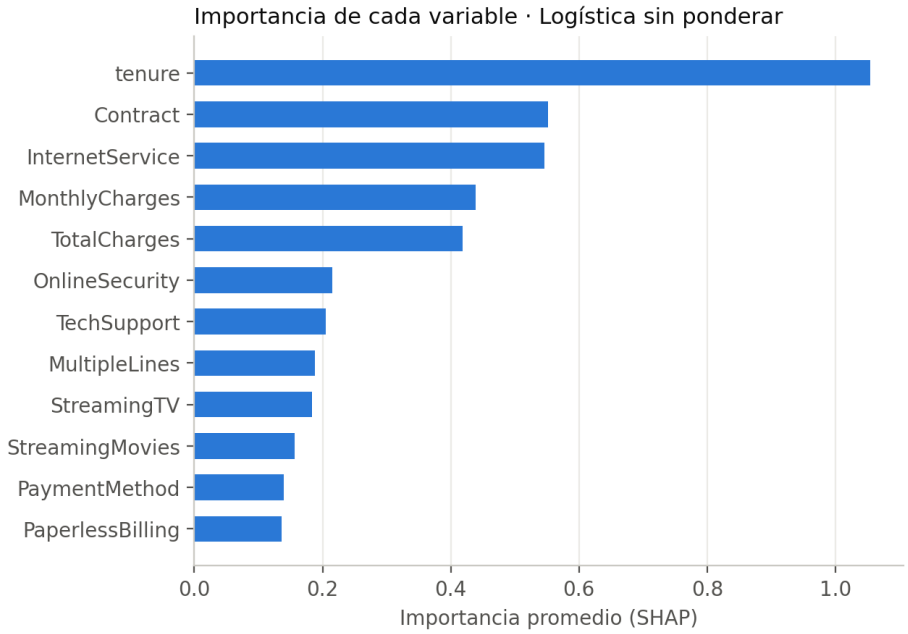


Figura 3. Importancia SHAP global agrupada por variable original (top 12).

La **antigüedad** es, por lejos, la variable más influyente (importancia 1,05), seguida por el **contrato** (0,55) y el **tipo de internet** (0,55). En dirección: el tercio de clientes más nuevos suma en promedio +1,35 y el más antiguo –1,40; el contrato mes a mes suma +0,49 y el de dos años resta 1,00; la fibra óptica suma +0,53. No tener TechSupport u OnlineSecurity suma entre +0,15 y +0,18.

Cautela con *MonthlyCharges*. En el EDA los cargos altos se asocian a más abandono, pero dentro del modelo su efecto es negativo: a igualdad de servicios contratados, un cargo más alto no suma riesgo. La razón es la colinealidad: la fibra óptica y el streaming ya explican por qué esos clientes pagan más. Por eso H4 no se sostiene por encima de los servicios.

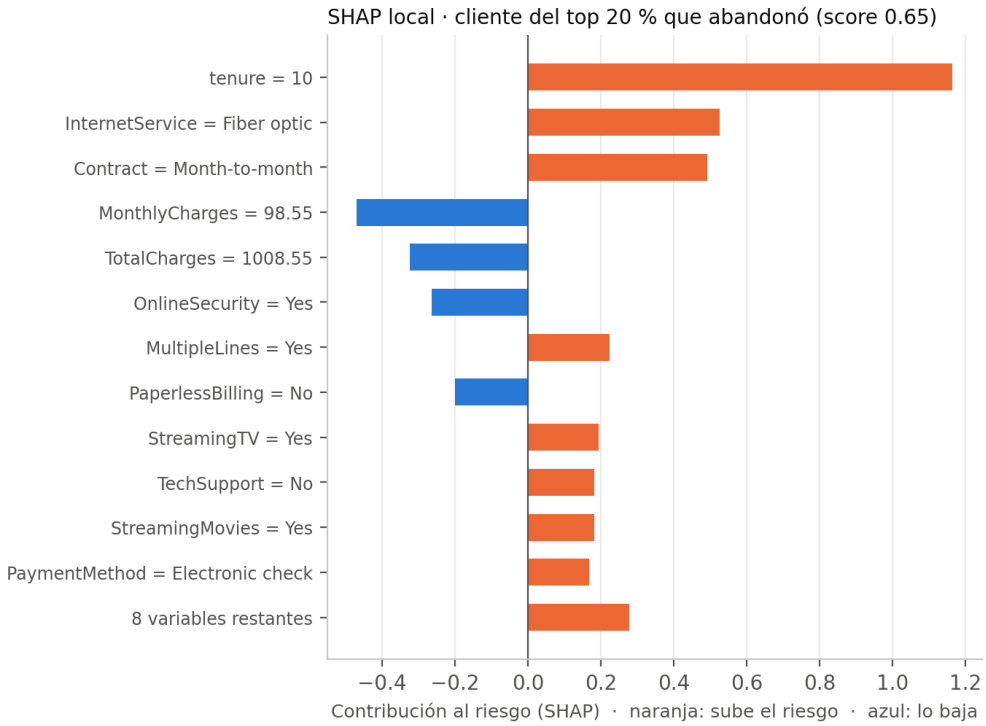


Figura 4. SHAP local de un cliente real del test que abandonó y quedó dentro del 20 % priorizado.

Caso local. La explicación parte del valor base del modelo (–1,52, equivalente a unos 18 % de probabilidad) y llega a un score de 0,65. Diez meses de antigüedad (+1,16), fibra óptica (+0,53) y contrato mes a mes (+0,49) empujan el riesgo hacia arriba; tener OnlineSecurity lo baja (–0,26). Para Retención la lectura es accionable: es un cliente nuevo, sin compromiso de permanencia y con un servicio de alto costo, candidato a una oferta de migración a contrato anual.

Prueba de quitar variables. Para medir el aporte propio de cada hipótesis se reentrenó el mismo modelo sacando cada grupo de variables (tabla completa en el repositorio). Quitar la antigüedad baja la PR-AUC 5,7 puntos; quitar solo el contrato, los servicios de soporte o el cargo mensual casi no la cambia; quitar contrato y antigüedad juntos la baja 7,6 puntos.

Veredicto de las hipótesis. H2 queda respaldada por el EDA, por SHAP y por la prueba de quitar variables. H1 se respalda en el EDA y en SHAP, pero su aporte se superpone con la antigüedad: quitar ambas juntas baja la PR-AUC 7,6 puntos. H3 tiene respaldo descriptivo y un aporte propio pequeño. H4 no se sostiene una vez que se conocen los servicios contratados.

6. Impacto en el negocio, riesgos y ética

Valor del cliente y costo de retenerlo. Retener a un cliente suele ser más barato que conseguir uno nuevo, pero solo vale la pena rescatar a los que valen más de lo que cuesta retenerlos. Con supuestos genéricos, para que el área los reemplace: el valor de un cliente en su ciclo de vida es su *MonthlyCharges* × 24 meses (el ciclo termina también por

mudanzas u otras causas ajenas al servicio); la acción retiene al 30 % de los contactados que iban a irse; y se evalúan tres costos por cliente retenido: USD 100, 1.000 y 10.000. Solo se contacta a quien vale más que su costo de retención. El cupo del 20 % se usa de tres formas: al azar, por riesgo (el ranking del modelo) y por **valor en riesgo** (probabilidad de abandono × valor del cliente), que prioriza a los que se van y además gastan mucho.

Costo por cliente retenido	Al azar	Por riesgo	Por valor en riesgo
USD 100	USD 276.469	USD 803.650	USD 823.584
USD 1.000	USD 189.909	USD 437.896	USD 454.640
USD 10.000	USD 0	USD 0	USD 0

Tabla 7. Valor neto preservado (valor de los clientes retenidos menos el costo de retenerlos) por cada 10.000 clientes.

Con USD 100 por cliente retenido, priorizar por valor en riesgo preserva USD 824 mil netos por cada 10.000 clientes, unas 3,0 veces más que contactar al azar, y algo más que priorizar solo por riesgo. Con USD 1.000 sigue conviniendo, porque el cliente retenido promedio de ese grupo vale unos USD 2.109. Con USD 10.000 no conviene retener a nadie: ningún cliente vale tanto (el máximo es USD 2.807) y ese dinero rinde más en conseguir clientes nuevos. El punto de corte es el valor del cliente: retener conviene mientras cueste menos de lo que el cliente deja en su ciclo de vida.

Iniciativas de retención según el perfil de riesgo. El ranking dice a quién contactar; SHAP sugiere qué ofrecer:

Perfil dentro del 20 % priorizado	Acción sugerida
Cliente nuevo (primeros 6-12 meses) con contrato mes a mes	Oferta de migración a contrato anual con beneficio de bienvenida (descuento o upgrade temporal).
Fibra óptica sin TechSupport ni OnlineSecurity	Incluir soporte técnico o seguridad online sin costo por un período, para aumentar el enganche.
Pago con Electronic check	Incentivo para pasar a débito automático (transferencia o tarjeta).
Score alto en cualquier perfil	Contacto proactivo del equipo de Retención antes del vencimiento de la factura.

Tabla 8. Acciones a validar en el piloto: son hipótesis de negocio derivadas del modelo, no efectos causales probados.

Auditoría ética. Se auditó el ranking por género, edad (*SeniorCitizen*) y personas a cargo (*Dependents*) (detalle en el Anexo C). En el test aparece una brecha de recall por género (61,8 % en mujeres contra 45,2 % en hombres; IC 95 % de la diferencia: 5,1 a 28,3

puntos), aunque ambos grupos abandonan a tasas parecidas. Sin embargo, la misma auditoría sobre las predicciones de la validación cruzada (4.507 clientes) no la reproduce (50,3 % contra 49,5 %): la brecha es propia de esa muestra de test y no un patrón sistemático. Los adultos mayores (tasa real 41 %) ocupan más lugares en el top 20 %, coherente con su mayor abandono. Los clientes **con dependientes** quedan sub-detectados de forma consistente (recall 24-34 % contra 55-58 %): abandonan menos, pero cuando lo hacen el modelo los ve menos. Quitar *gender* y *SeniorCitizen* no cambia el desempeño (PR-AUC 0,664 contra 0,666), por lo que se recomienda excluirlos en producción.

Riesgo	Mitigación
Datos estáticos, sin fechas: no se sabe si el patrón se mantiene en el tiempo	Reentrenar periódicamente y monitorear Recall @ 20 % y la distribución de las variables.
Diferencias de recall entre grupos (dependientes; brecha de género en test)	Auditoría por grupo en cada campaña; excluir atributos sensibles que no aportan.
Profecía autocumplida: solo se observa la retención de quienes se contactan	Reservar un grupo de control aleatorio (el piloto A/B) en cada campaña.
Supuestos económicos no validados	Medir costo real por retenido y tasa de éxito en el piloto antes de escalar.
Clientes que solo buscan promociones: no hay datos de uso de promociones	Priorizar por valor (gasto alto) y registrar quién acepta ofertas para excluirlos en campañas futuras.
Privacidad de datos de clientes	Minimización de datos, control de accesos y uso de datos anonimizados.

Tabla 9. Riesgos y mitigaciones.

Automatización y escalabilidad. Hoy la selección de a quién contactar no sigue un criterio; con el modelo pasa a ser un proceso automático: el pipeline entrena en segundos y puntúa la cartera completa al instante, por lo que puede ejecutarse antes de cada campaña y extenderse a otros productos cambiando la variable objetivo.

7. Conclusiones y recomendaciones

- El problema se formuló como priorización bajo un cupo de contactos: Recall @ 20 % y PR-AUC reflejan la decisión mejor que accuracy.
- Contactando al 20 % de mayor riesgo, el modelo detecta el 53,2 % de los abandonos (2,65 veces más que al azar). Cumple el mínimo de 50 % pero no la meta de 55 %.

- Random Forest, Gradient Boosting, SMOTE y la ponderación de clases no mejoran el ranking de la Regresión Logística: se elige el modelo más simple, interpretable y con probabilidades más realistas.
- La antigüedad y el tipo de contrato son el núcleo de la señal; el riesgo se concentra en clientes nuevos, con contrato mes a mes, fibra óptica y sin servicios de soporte.
- Retener conviene mientras cueste menos que el valor del cliente: con USD 100 o 1.000 por retenido el valor neto es positivo y mayor si se prioriza por valor en riesgo; con USD 10.000 no conviene.

Recomendación. No desplegar de forma automática. Ejecutar un piloto A/B con el mismo presupuesto (20 % priorizado por el modelo por valor en riesgo contra 20 % al azar), medir retención real, costo por cliente retenido y Recall @ 20 % por grupo, excluir *gender* y *SeniorCitizen* del modelo, y escalar solo si el piloto confirma el beneficio. Como acción de negocio inmediata, los hallazgos sugieren campañas de migración de contrato mensual a anual en los primeros meses de vida del cliente y la oferta de TechSupport/OnlineSecurity a clientes de fibra óptica.

Código. El notebook completo está en el repositorio público github.com/jgrozo660/Proyecto-Final-AnalisisDeDatos-UTN y puede ejecutarse en Google Colab (Anexo D).

Próximos pasos. Incorporar variables de interacción con el cliente (reclamos, llamadas al soporte) y datos con fecha, que permitirían validar el modelo hacia adelante en el tiempo.

Anexos

Material complementario, fuera del límite de 12 páginas del cuerpo. Las tablas y figuras completas (deciles, curvas ROC y de calibración, prueba de quitar variables, escenarios de valor del cliente) están en la carpeta *results/* del repositorio.

Anexo A. Devolución de la pre-entrega

Devolución del tutor	Cómo se resolvió
Usar "tasa de churn observada en la muestra" en lugar de "mensual"	Aplicado. El KPI pasa a ser el % de abandonos detectados con el 20 % contactado.
Comparar el baseline con Random Forest o Gradient Boosting, sin modelos de relleno	Se comparan ambos (sección 4).
Incorporar PR-AUC además de Recall y ROC-AUC	PR-AUC es la métrica técnica principal.
Traducir a negocio: contactando al 20 %, ¿qué % de abandonos se detecta?	53,2 % (Tabla 6, Figura 2).
Si se usa SMOTE, solo sobre entrenamiento	Aplicado dentro del pipeline; no mejora.

Tabla A1. Devolución del tutor y su resolución.

Métrica (mismo test)	Pre-entrega	Entrega final
ROC-AUC	0,848	0,848
PR-AUC / abandonos detectados con el 20 %	no reportados	0,666 / 53,2 %
Recall / precisión con umbral de decisión	79,9 % / 52,4 % (umbral 0,5)	72,6 % / 56,7 % (umbral 0,328)

Tabla A2. Pre-entrega contra entrega final: el modelo ordena igual de bien; mejora cómo se mide y se usa.

Anexo B. Matriz de confusión y reporte por clase

Test, umbral 0,328	Predicho No	Predicho Sí	Precisión	Recall	F1
Real: no abandona	662	166	0,890	0,800	0,842
Real: abandona	82	217	0,567	0,726	0,636

Tabla B1. Modelo elegido sobre el test (1.127 clientes). Accuracy 0,780.

Anexo C. Auditoría por grupos (top 20 %)

Atributo	Grupo	Tasa real	% del top 20	Recall (test)	Recall (validación cruzada)
gender	Female	25,5 %	57,1 %	61,8 %	50,3 %
gender	Male	27,6 %	42,9 %	45,2 %	49,5 %
SeniorCitizen	No	23,4 %	67,3 %	48,4 %	44,7 %
SeniorCitizen	Yes	41,9 %	32,7 %	66,2 %	65,8 %
Dependents	No	30,2 %	87,6 %	57,7 %	55,0 %
Dependents	Yes	17,7 %	12,4 %	34,5 %	24,4 %

Tabla C1. Validación cruzada: predicciones sobre 4.507 clientes, cada uno evaluado por un modelo que no lo vio en el entrenamiento. Una diferencia de tasa real no prueba ausencia de sesgo.

Anexo D. Código y fuentes

Repositorio: https://github.com/jgrozo660/Proyecto-Final-AnalisisDeDatos-UTN (notebook ejecutado, datos, *data_log.md*, *README.md* con instrucciones, *results/* y *docs/*).

Notebook en Google Colab: abrir proyecto_integrador.ipynb en Colab. La primera celda clona el repositorio e instala lo necesario. Semilla fija: *random_state* = 42.

- Kaggle. *Predicción de fuga de cliente* [competencia]. kaggle.com/competitions/prediccion-de-fuga-de-cliente
- Chapman, P. et al. (2000). *CRISP-DM 1.0*. SPSS.
- Chawla, N. et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *JAIR*, 16.
- Lundberg, S. y Lee, S.-I. (2017). A unified approach to interpreting model predictions. *NeurIPS 30*.