Diplomado en Ciencia de Datos y Análisis Avanzado

UTN.BA · Unidad 9 · Proyecto Final Integrador

# Informe Final

Priorización de acciones de retención: predicción de abandono (churn) de clientes en una empresa de telecomunicaciones

**Integrantes**

Agustín Bilche Braga

Agustina Díaz

Carlos Grozo

Milagros Crespo

Luana Zalcman

Octubre de 2026

# Índice


- 1. Resumen ejecutivo
- 2. Definición del problema y relevancia
- 3. Datos y metodología
- 4. Modelado y evaluación
- 5. Interpretación del modelo
- 6. Impacto en el negocio, riesgos y ética
- 7. Conclusiones y recomendaciones
- Anexos: A. Trazabilidad con la consigna, la pre-entrega y la devolución · B. Lift por deciles · C. Auditoría por grupos · D. Reproducibilidad y fuentes


## 1. Resumen ejecutivo

**Problema.** Una empresa de telecomunicaciones pierde a cerca de 1 de cada 4 clientes de su cartera: la **tasa de churn observada en la muestra** es 26,5 %. El área de Retención puede contactar aproximadamente al 20 % de la cartera por campaña y hoy no tiene un criterio para elegir a quién.

**Solución.** Un modelo de Regresión Logística que ordena a los clientes por riesgo estimado de abandono, para que el cupo de contactos se use primero con quienes tienen mayor score. Se compararon cinco variantes (incluidos Random Forest y Gradient Boosting) y quedaron estadísticamente empatadas; una regla definida antes de mirar el test elige la más simple e interpretable.

| Indicador (test interno, 1.127 clientes) | Contacto al azar | Modelo |
|---|---|---|
| Abandonos detectados contactando al 20 % de mayor riesgo | 20,1 % | **53,2 %** |
| Precisión dentro del 20 % contactado | 26,6 % | 70,4 % |
| PR-AUC (piso = tasa de churn 0,265) | 0,270 | 0,666 (×2,5) |
| Beneficio neto anual estimado por 10.000 clientes* | USD 116.848 | USD 392.907 |

Tabla 1. Resultados principales. *Escenario paramétrico con supuestos explícitos (sección 6), no costos reales de la empresa.

**Resultado.** Contactando al 20 % mejor rankeado se detecta el **53,2 %** de los clientes que realmente abandonan, 2,65 veces más que al azar (IC 95 %: 49,2 % a 57,9 %). Con una tasa de 26,5 %, contactar al 20 % permite detectar como máximo el 75 %. La meta definida antes de entrenar era 55 % (mínimo aceptable 50 %): **se cumple el mínimo pero no la meta**.

**Qué explica el riesgo.** La antigüedad es la variable más influyente (los primeros seis meses concentran el abandono), seguida por el contrato mes a mes, la fibra óptica y la falta de servicios de soporte.

**Recomendación.** Usar el ranking como herramienta de priorización con intervención humana y validarlo con un **piloto A/B** (20 % priorizado por el modelo contra 20 % al azar) antes de escalarlo, midiendo la tasa real de retención.

## 2. Definición del problema y relevancia

La pregunta de negocio no es "quién se va a ir con certeza", sino **a quién contactar primero** con un cupo limitado de llamadas e incentivos. Por eso el producto es un ranking de riesgo y no solo una clasificación sí/no. Retener a un cliente suele costar menos que adquirir uno nuevo, y cada contacto a un cliente que no iba a irse es capacidad perdida.

**Objetivo medible (definido antes de correr los modelos de esta entrega):** detectar ≥ 55 % de los abandonos contactando al 20 % de la cartera (mínimo aceptable 50 %). **Benchmark:** un orden aleatorio detecta ~20 %. **Techo:** 0,20 / 0,265 ≈ 75 %.

| Situación | Lectura estadística | Costo de negocio |
|---|---|---|
| Cliente contactado que no iba a irse | Falso positivo dentro del cupo | Consume un contacto y, si hay incentivo, un descuento innecesario. |
| Cliente que se va y quedó fuera del 20 % | Falso negativo operativo | Se pierde su facturación futura. |
| Predecir siempre "no abandona" | Accuracy ≈ 73,5 % | Parece aceptable, pero no prioriza a nadie. |

Tabla 2. Costo de cada tipo de error.

**Hipótesis** (de la pre-entrega):

- **H1:** el contrato mes a mes concentra más abandono que los contratos de 1 o 2 años.
- **H2:** a menor antigüedad, mayor abandono.
- **H3:** no tener TechSupport u OnlineSecurity y pagar con Electronic check se asocian a más abandono.
- **H4:** cargos mensuales más altos se asocian a más abandono.

## 3. Datos y metodología

**Fuente.** Competencia de Kaggle *Predicción de fuga de cliente* (kaggle.com/competitions/prediccion-de-fuga-de-cliente), basada en el dataset Telco Customer Churn. **train.csv**: 5.634 clientes y 21 columnas (perfil, servicios contratados, contrato, facturación y *Churn*). **test.csv**: 1.409 clientes sin *Churn*, usados solo para generar predicciones. El dataset es una foto estática: no tiene fechas, por lo que no se puede hablar de una tasa mensual ni hacer validación temporal.

| Hallazgo de calidad | Decisión y motivo |
|---|---|
| 0 nulos explícitos, pero los 8 clientes con *tenure* = 0 traen *TotalCharges* = 1.397,475 (la mediana) | **Corregido a 0**: el archivo venía pre-imputado. Un cliente sin meses facturados no acumuló cargos. La pre-entrega había reportado "sin nulos". |
| 15 filas idénticas salvo el *customerID* | Se conservan: son clientes distintos con el mismo perfil. |
| *TotalCharges* ≈ *tenure* × *MonthlyCharges* (mediana del cociente 1,00) | Se descarta el "cargo promedio por mes" pendiente de la pre-entrega: repetiría *MonthlyCharges*. |
| Servicios adicionales dispersos en 6 columnas | Se agrega *n_servicios* (0-6) como resumen del "enganche" del cliente. |
| Desbalance: 26,5 % abandona | Métricas de ranking (Recall @ 20 %, PR-AUC); accuracy solo como referencia. |

Tabla 3. Calidad de datos y decisiones (detalle en data_log.md).

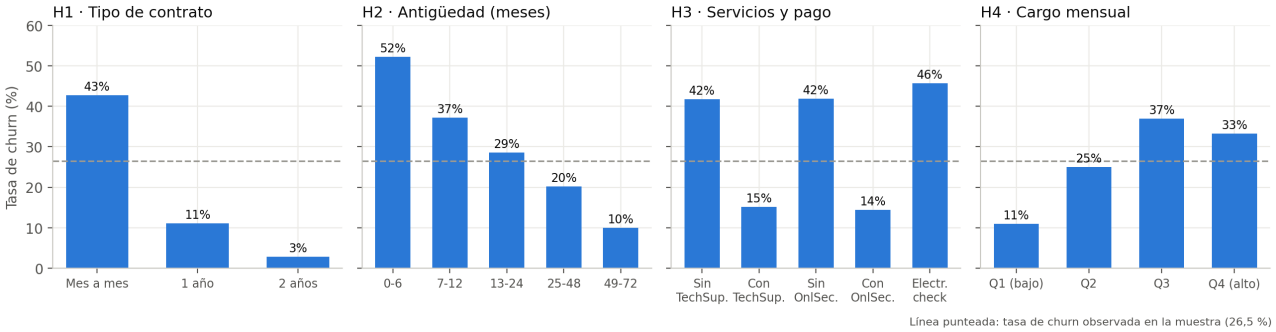



Figura 1. Tasa de churn por contrato (H1), antigüedad (H2), servicios y forma de pago (H3) y cuartil de cargo mensual (H4). Línea punteada: tasa observada en la muestra.

### Conclusiones del EDA.

- **H1:** el contrato mes a mes abandona 42,8 %, contra 11,1 % (1 año) y 2,9 % (2 años).
- **H2:** el abandono es 52,2 % en los primeros seis meses y baja de forma monótona hasta 9,9 % después de los cuatro años.
- **H3:** sin TechSupport u OnlineSecurity la tasa ronda 42 %, contra 14-15 % con el servicio; Electronic check llega a 45,7 %.
- **H4:** el abandono crece del cuartil más bajo (10,9 %) al tercero (37,0 %), pero baja levemente en el más alto (33,3 %).
- Contrato, antigüedad y cargos están relacionados entre sí: el EDA es descriptivo y el aporte propio de cada bloque se mide con ablaciones (sección 5).

**Metodología.** Se siguió CRISP-DM: negocio (sección 2), comprensión y preparación de datos (sección 3), modelado y evaluación (sección 4) y traducción a una decisión (secciones 5-6). Todo el preprocesamiento (One-Hot para categóricas, escalado para numéricas) vive dentro de un *Pipeline* que se ajusta solo con datos de entrenamiento, con *random_state* = 42 y las decisiones registradas en *data_log.md*.

| Diseño de validación | Pregunta que responde |
|---|---|
| CV estratificada de 5 folds sobre el 80 % de desarrollo | ¿Qué modelo ordena mejor? Define el candidato. |
| Test estratificado 20 % (misma partición que la pre-entrega), usado una sola vez | ¿Cuánto rinde con clientes no vistos? |
| Bootstrap del test (2.000 remuestreos) | ¿Las diferencias entre modelos son mayores que el ruido? |
| Predicciones out-of-fold del desarrollo | Elegir el umbral sí/no y repetir la auditoría ética sin usar el test. |

Tabla 4. Diseño de validación. No hay validación temporal porque los datos no tienen fechas.

## 4. Modelado y evaluación

Siguiendo la devolución de la pre-entrega, el baseline se comparó con Random Forest y Gradient Boosting. Cada variante responde una pregunta concreta: la logística **balanceada** es el baseline de la pre-entrega; la **sin ponderar** mide si la ponderación cambia el ranking o solo el umbral; la variante con **SMOTE** mide si sobremuestrear ayuda (SMOTE vive dentro de un *imblearn.Pipeline*, así que solo se aplica sobre los datos de entrenamiento de cada fold); Random Forest (500 árboles, hoja mínima 5) y Gradient Boosting (300 árboles, profundidad 3) miden si un modelo no lineal captura algo más.

**Regla de selección definida antes de ver el test:** los modelos a menos de un desvío estándar de la mejor PR-AUC media en CV se consideran empatados; entre empatados se elige el más simple (logística sin ponderar → balanceada → SMOTE → Random Forest → Gradient Boosting).

| Modelo | PR-AUC CV (media ± desvío) | ROC-AUC CV | Recall @ 20 % CV |
|---|---|---|---|
| **Logística sin ponderar** | **0,659 ± 0,023** | **0,844** | **50,4 %** |
| Logística + SMOTE (solo train) | 0,659 ± 0,024 | 0,844 | 49,8 % |
| Logística balanceada (pre-entrega) | 0,657 ± 0,024 | 0,843 | 50,1 % |
| Random Forest | 0,657 ± 0,031 | 0,843 | 50,1 % |
| Gradient Boosting | 0,653 ± 0,043 | 0,839 | 48,6 % |

Tabla 5. Validación cruzada de 5 folds sobre 4.507 clientes. Umbral de empate: 0,636. Los cinco modelos quedan empatados.

Los cinco modelos quedan dentro del margen de empate (PR-AUC entre 0,653 y 0,659, con desvíos de 0,02 a 0,04). La regla elige la **Regresión Logística sin ponderar**. Dos lecturas: la ponderación de clases y SMOTE no cambian el ranking (solo mueven el umbral), y los árboles no encuentran interacciones que la logística no capture.

| Modelo (test) | PR-AUC | ROC-AUC | Recall @ 20 % | Precisión @ 20 % | Lift @ 20 % | Brier |
|---|---|---|---|---|---|---|
| Ranking aleatorio | 0,270 | 0,500 | 20,1 % | 26,6 % | 1,00 | - |
| **Logística sin ponderar** | **0,666** | **0,848** | **53,2 %** | **70,4 %** | **2,65** | **0,133** |
| Logística + SMOTE (solo train) | 0,667 | 0,849 | 53,5 % | 70,8 % | 2,67 | 0,159 |
| Logística balanceada (pre-entrega) | 0,666 | 0,848 | 53,2 % | 70,4 % | 2,65 | 0,163 |
| Random Forest | 0,655 | 0,847 | 51,5 % | 68,1 % | 2,57 | 0,134 |
| Gradient Boosting | 0,673 | 0,853 | 52,8 % | 69,9 % | 2,64 | 0,132 |

Tabla 6. Evaluación única sobre el 20 % de test (1.127 clientes, 299 abandonos). Brier: error de las probabilidades (menor es mejor).

En el test, Gradient Boosting obtiene la PR-AUC más alta (0,673 contra 0,666), pero la diferencia no es significativa: el intervalo de 95 % por bootstrap de la diferencia va de -0,034 a +0,018, y en Recall @ 20 % de -2,3 a +3,6 puntos. Coincide con la CV: no hay un ganador claro, y la regla ex ante no se cambia por el resultado del test.

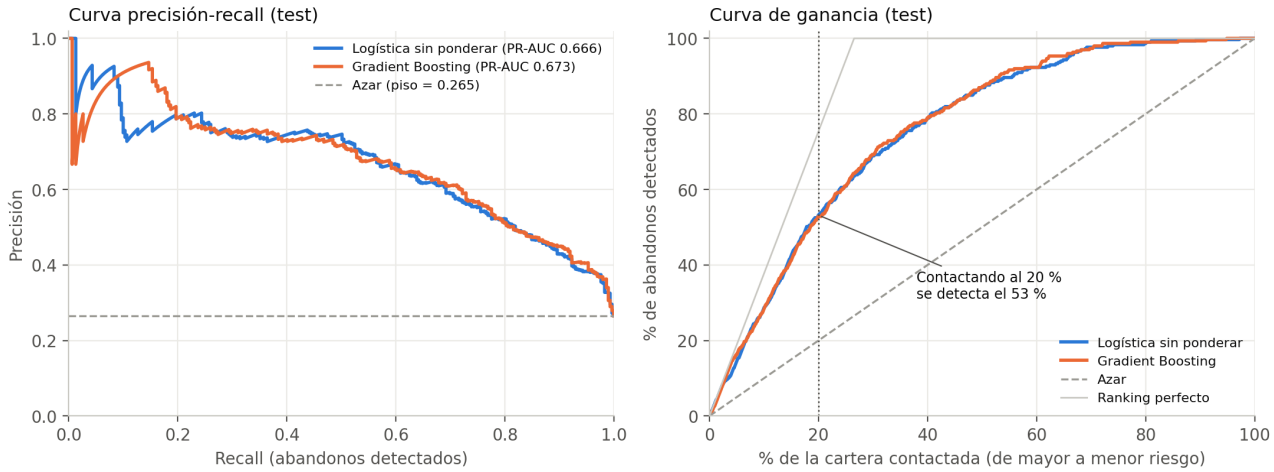



Figura 2. Curva precisión-recall y curva de ganancia en el test. Línea vertical punteada: cupo de 20 %. Las curvas de la logística y de Gradient Boosting prácticamente se superponen.

| % de la cartera contactada | Abandonos detectados | Precisión | Lift |
|---|---|---|---|
| 10 % | 28,8 % | 76,1 % | 2,87 |
| **20 %** | **53,2 %** | **70,4 %** | **2,65** |
| 30 % | 68,9 % | 60,8 % | 2,29 |
| 40 % | 78,9 % | 52,3 % | 1,97 |
| 50 % | 87,0 % | 46,1 % | 1,74 |

Tabla 7. Abandonos detectados según el porcentaje de la cartera contactada (modelo elegido, test).

**Calibración y umbral.** La ponderación de clases y SMOTE inflan las probabilidades: la logística balanceada de la pre-entrega tiene Brier 0,163 contra 0,133 de la sin ponderar, cuya curva de calibración sigue de cerca la diagonal. Por eso el score del modelo elegido puede leerse como una probabilidad aproximada. Si se necesita una etiqueta sí/no (por ejemplo, para la competencia), el umbral se eligió maximizando F1 con las predicciones

out-of-fold del desarrollo, sin mirar el test: 0,328. Con él, en el test se detecta el 72,6 % de los abandonos con precisión 56,7 % (F1 0,636), marcando como riesgo al 34,0 % de los clientes.

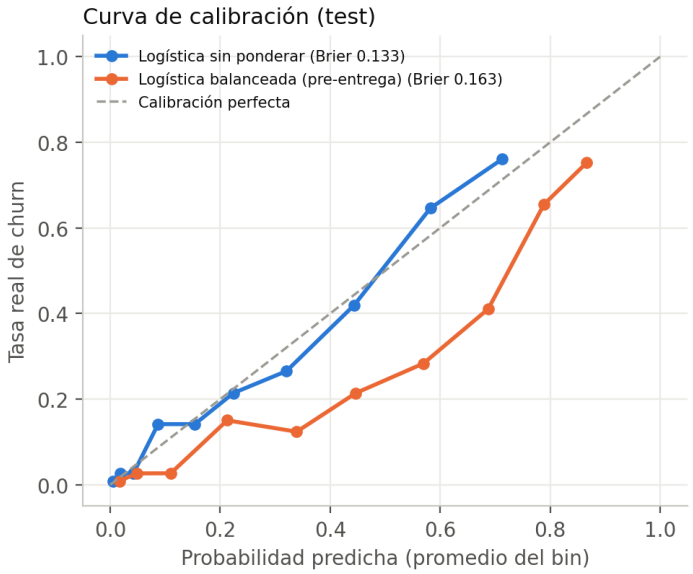



Figura 3. Curva de calibración en el test: logística sin ponderar (azul) contra la balanceada de la pre-entrega (naranja).

## 5. Interpretación del modelo

Se usó SHAP (*LinearExplainer*) sobre los 1.127 clientes del test. Las columnas One-Hot se sumaron por variable original, así el negocio lee "Contract" y no tres columnas. En una regresión logística SHAP se expresa en log-odds: el signo indica si la variable sube o baja el riesgo y la magnitud cuánto lo mueve. **SHAP describe cómo razona el modelo; no demuestra causalidad.**

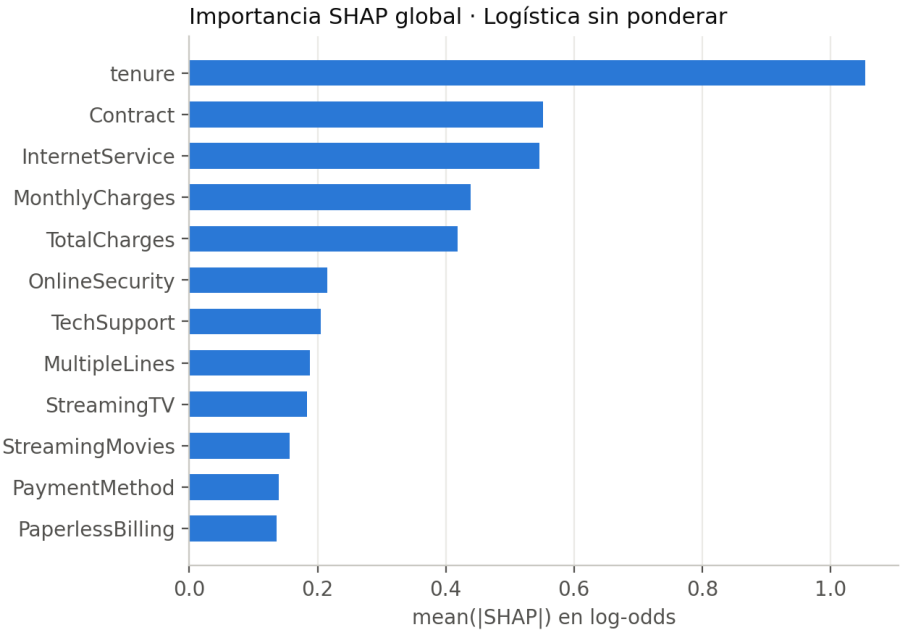



Figura 4. Importancia SHAP global agrupada por variable original (top 12).

La **antigüedad** es, por lejos, la variable más influyente (mean|SHAP| 1,05), seguida por el **contrato** (0,55) y el **tipo de internet** (0,55). En dirección: el tercio de clientes más nuevos suma en promedio +1,35 log-odds y el más antiguo –1,40; el contrato mes a mes suma +0,49 y el de dos años resta 1,00; la fibra óptica suma +0,53. No tener TechSupport u OnlineSecurity suma entre +0,15 y +0,18.

**Cautela con *MonthlyCharges*.** En el EDA los cargos altos se asocian a más abandono, pero dentro del modelo su efecto es negativo: a igualdad de servicios contratados, un cargo más alto no suma riesgo. La razón es la colinealidad: la fibra óptica y el streaming ya explican por qué esos clientes pagan más. Por eso H4 no se sostiene por encima de los servicios.

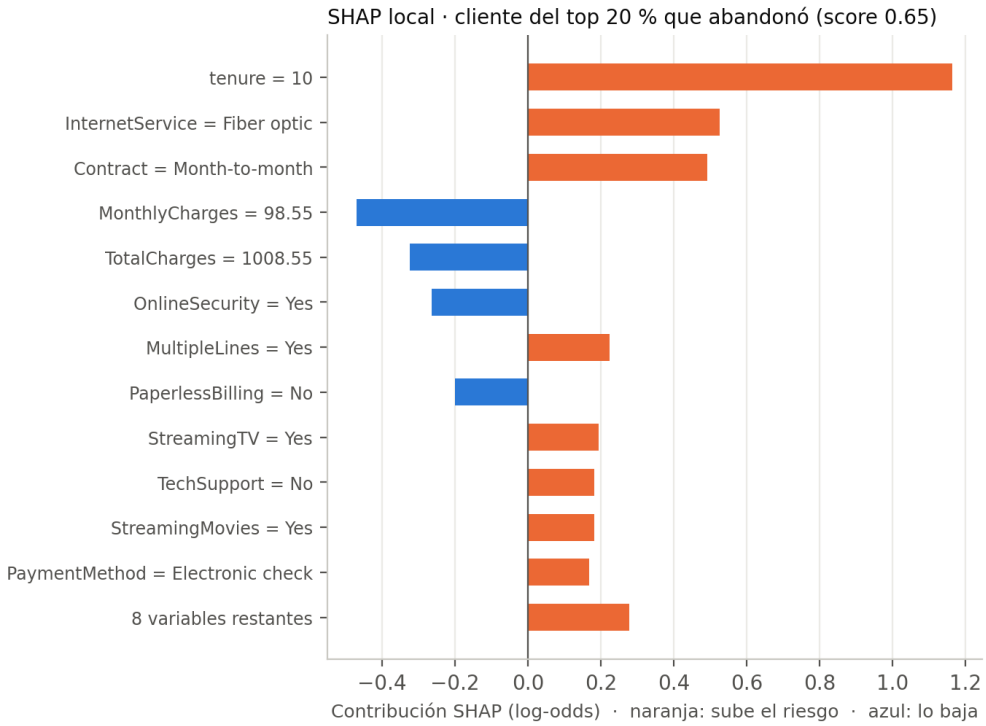



Figura 5. SHAP local de un cliente real del test que abandonó y quedó dentro del 20 % priorizado.

**Caso local.** La explicación parte del valor base del modelo (–1,52 log-odds, unos 18 % de probabilidad) y llega a un score de 0,65. Diez meses de antigüedad (+1,16), fibra óptica (+0,53) y contrato mes a mes (+0,49) empujan el riesgo hacia arriba; tener OnlineSecurity lo baja (–0,27). Para Retención la lectura es accionable: es un cliente nuevo, sin compromiso de permanencia y con un servicio de alto costo, candidato a una oferta de migración a contrato anual.

| Ablación sobre el mismo test | PR-AUC | Δ PR-AUC | Δ Recall @ 20 % | Lectura |
|---|---|---|---|---|
| Modelo completo | 0,666 | - | - | Referencia |
| H1: sin Contract | 0,663 | -0,3 p.p. | +0,3 p.p. | Casi sin caída: la antigüedad cuenta la misma historia. |
| H2: sin antigüedad (tenure, TotalCharges) | 0,609 | -5,7 p.p. | -4,7 p.p. | **Mayor caída individual.** H2 respaldada. |
| H3: sin servicios de soporte y forma de pago | 0,660 | -0,6 p.p. | +0,3 p.p. | Caída pequeña: otras variables los sustituyen. |
| H4: sin MonthlyCharges | 0,667 | +0,1 p.p. | 0,0 p.p. | Sin caída: H4 no aporta por encima de los servicios. |
| Contrato + antigüedad juntos | 0,590 | -7,6 p.p. | -5,7 p.p. | **La caída más grande**: H1 y H2 juntas son el núcleo de la señal. |

Tabla 8. Ablaciones: se reentrena el mismo pipeline sin cada bloque. Con 299 abandonos en el test, cambios menores a ~1-2 puntos están dentro del ruido.

**Veredicto de las hipótesis.** H2 queda respaldada por el EDA, por SHAP y por la ablación. H1 se respalda en el EDA y en SHAP, pero su aporte se superpone con la antigüedad: quitar ambas juntas baja la PR-AUC 7,6 puntos. H3 tiene respaldo descriptivo y un aporte propio pequeño. H4 no se sostiene una vez que se conocen los servicios contratados.

## 6. Impacto en el negocio, riesgos y ética

**Escenario económico.** No se cuenta con costos reales de la empresa, por lo que se usan supuestos explícitos para que el área los reemplace: USD 15 por cliente contactado (llamada + incentivo), 30 % de éxito de la acción sobre un cliente que iba a irse, y como valor de un cliente retenido su *MonthlyCharges* real × 12 meses. Se calcula sobre el test y se escala a una cartera de 10.000 clientes.

| Escenario (10.000 clientes) | Contactos | Abandonos detectados | Retenidos esperados | Ingreso anual preservado | Beneficio neto |
|---|---|---|---|---|---|
| Modelo: top 20 % | 2.005 | 1.411 | 423 | USD 422.987 | USD 392.907 |
| Azar: 20 % aleatorio | 2.005 | 532 | 160 | USD 146.927 | USD 116.848 |
| **Diferencia** | **0** | **879** | **264** | **USD 276.060** | **USD 276.060** |

Tabla 9. Escenario económico paramétrico con el recall medido en el test.

Con el mismo presupuesto de contactos, el modelo detecta unos 879 abandonos más que el azar y agrega cerca de USD 276 mil de beneficio neto anual por cada 10.000 clientes. El monto depende fuertemente de la tasa de éxito: con 15 % el beneficio del modelo cae a USD 181 mil y con 45 % sube a USD 604 mil (ver results/sensibilidad_economica.csv). Esa tasa es justamente lo que el piloto debe medir.

**Auditoría ética.** Se auditó el ranking por género, edad (*SeniorCitizen*), pareja y dependientes (detalle en el Anexo C). En el test aparece una brecha de recall por género

(61,8 % en mujeres contra 45,2 % en hombres; IC 95 % de la diferencia: 5,1 a 28,3 puntos), aunque ambos grupos abandonan a tasas parecidas. Sin embargo, la misma auditoría sobre las predicciones out-of-fold de 4.507 clientes no la reproduce (50,3 % contra 49,5 %): la brecha es propia de esa muestra de test y no un patrón sistemático. Los adultos mayores (tasa real 41 %) ocupan más lugares en el top 20 %, coherente con su mayor abandono. Los clientes **con dependientes** quedan sub-detectados de forma consistente (recall 24-34 % contra 55-58 %): abandonan menos, pero cuando lo hacen el modelo los ve menos. Quitar *gender* y *SeniorCitizen* no cambia el desempeño (PR-AUC 0,664 contra 0,666), por lo que se recomienda excluirlos en producción.

| Riesgo | Mitigación |
|---|---|
| Datos estáticos, sin fechas: no se sabe si el patrón se mantiene en el tiempo | Reentrenar periódicamente y monitorear Recall @ 20 % y la distribución de las variables. |
| Diferencias de recall entre grupos (dependientes; brecha de género en test) | Auditoría por grupo en cada campaña; excluir atributos sensibles que no aportan. |
| Profecía autocumplida: solo se observa la retención de quienes se contactan | Reservar un grupo de control aleatorio (el piloto A/B) en cada campaña. |
| Supuestos económicos no validados | Medir costo real por contacto y tasa de éxito en el piloto antes de escalar. |
| Privacidad de datos de clientes | Minimización de datos, control de accesos y cumplimiento de la Ley 25.326 de Protección de Datos Personales. |

Tabla 10. Riesgos y mitigaciones.

**Escalabilidad.** El pipeline entrena en segundos y puntúa la cartera completa al instante; puede ejecutarse antes de cada campaña y extenderse a otros productos cambiando la variable objetivo y repitiendo la auditoría.

# 7. Conclusiones y recomendaciones

- El problema se formuló como priorización bajo un cupo de contactos: Recall @ 20 % y PR-AUC reflejan la decisión mejor que accuracy.
- Contactando al 20 % de mayor riesgo, el modelo detecta el 53,2 % de los abandonos (2,65 veces el azar). Cumple el mínimo de 50 % pero no la meta de 55 %.
- Random Forest, Gradient Boosting, SMOTE y la ponderación de clases no mejoran el ranking de la Regresión Logística: se elige el modelo más simple, interpretable y mejor calibrado.
- La antigüedad y el tipo de contrato son el núcleo de la señal; el riesgo se concentra en clientes nuevos, con contrato mes a mes, fibra óptica y sin servicios de soporte.
- El valor económico es positivo bajo supuestos razonables, pero depende de la tasa de éxito de la acción de retención, que todavía no se conoce.

**Recomendación.** No desplegar de forma automática. Ejecutar un piloto A/B con el mismo presupuesto (20 % priorizado por el modelo contra 20 % al azar), medir retención real, costo por cliente retenido y Recall @ 20 % por grupo, excluir *gender* y *SeniorCitizen* del modelo, y escalar solo si el piloto confirma el beneficio. Como acción de negocio inmediata, los hallazgos sugieren campañas de migración de contrato mensual a anual en los primeros meses de vida del cliente y la oferta de TechSupport/OnlineSecurity a clientes de fibra óptica.

**Próximos pasos.** Incorporar variables de interacción con el cliente (reclamos, llamadas al soporte) y datos con fecha, que permitirían validar el modelo hacia adelante en el tiempo.

# Anexo A. Trazabilidad con la consigna, la pre-entrega y la devolución

| Criterio de evaluación | Evidencia en el informe |
|---|---|
| Problema y alineación con negocio | Secciones 1-2: decisión, objetivo ex ante, benchmark, techo y costo del error. |
| Datos, metodología y justificación técnica | Sección 3: calidad con cifras (centinela de TotalCharges), CRISP-DM, diseño de validación. |
| Selección y defensa del modelo | Sección 4: CV, regla ex ante, empate, bootstrap (Tablas 5-6). |
| Calidad de las métricas | PR-AUC con piso, Recall/Precisión/Lift @ 20 %, captura por cupo, calibración, deciles. |
| Interpretación y cuantificación de valor | Sección 5 (SHAP, ablaciones) y sección 6 (escenario económico y sensibilidad). |
| Ética y privacidad | Sección 6 y Anexo C: auditoría por grupos en test y OOF, modelo sin atributos sensibles. |
| Impacto y claridad | Resumen en lenguaje no técnico, figuras y recomendación proporcional a la evidencia. |

| Devolución del tutor | Estado en la entrega final |
|---|---|
| Usar "tasa de churn observada en la muestra" en lugar de "mensual" | Aplicado en todo el informe y el repositorio. |
| Comparar el baseline con Random Forest o Gradient Boosting, sin modelos de relleno | Se comparan ambos; cada variante responde una pregunta (sección 4). |
| Incorporar PR-AUC además de Recall y ROC-AUC | PR-AUC es la métrica técnica principal, siempre junto a su piso. |
| Traducir a negocio: contactando al 20 %, ¿qué % de abandonos se detecta? | 53,2 % (Tabla 7, Figura 2). |
| Si se usa SMOTE, solo sobre entrenamiento | SMOTE dentro de un imblearn.Pipeline por fold; no mejora el ranking. |

| Comprometido en la pre-entrega | Estado en la entrega final |
|---|---|
| Dataset de Kaggle y limpieza tomada | Aplicado; se detectó y corrigió el centinela de TotalCharges. |
| Pendiente: variables derivadas | Cargo promedio por mes descartado (redundante); se agregó n_servicios. |
| Probar Random Forest y Gradient Boosting | Hecho (Tablas 5-6). |
| Explorar SMOTE y ajuste de umbral | Hecho: SMOTE no mejora; umbral elegido con OOF (sección 4). |
| Predicciones sobre test.csv y cuantificación de impacto | results/predicciones_test.csv y sección 6. |
| Meta de la pre-entrega: Recall ≥ 0,75 y ROC-AUC ≥ 0,80 con umbral 0,5 | Reformulada como ranking por la devolución. Con el umbral OOF: recall 72,6 %; ROC-AUC 0,848. |

## Anexo B. Lift por deciles (modelo elegido, test)

| Decil | Clientes | Abandonos | Tasa | Lift | Recall acumulado |
|---|---|---|---|---|---|
| 1 | 113 | 86 | 76,1 % | 2,87 | 28,8 % |
| 2 | 112 | 73 | 65,2 % | 2,46 | 53,2 % |
| 3 | 113 | 47 | 41,6 % | 1,57 | 68,9 % |
| 4 | 113 | 30 | 26,5 % | 1,00 | 78,9 % |
| 5 | 113 | 24 | 21,2 % | 0,80 | 87,0 % |
| 6 | 112 | 16 | 14,3 % | 0,54 | 92,3 % |
| 7 | 113 | 16 | 14,2 % | 0,53 | 97,7 % |
| 8 | 113 | 3 | 2,7 % | 0,10 | 98,7 % |
| 9 | 112 | 3 | 2,7 % | 0,10 | 99,7 % |
| 10 | 113 | 1 | 0,9 % | 0,03 | 100,0 % |

Tabla B1. El primer decil abandona 76,1 % (lift 2,87); los dos primeros deciles concentran el 53,2 % de los abandonos.

## Anexo C. Auditoría por grupos (top 20 %)

| Atributo | Grupo | Clientes | Tasa real | % de la cartera | % del top 20 | Recall (test) | Recall (OOF) |
|---|---|---|---|---|---|---|---|
| gender | Female | 565 | 25,5 % | 50,1 % | 57,1 % | 61,8 % | 50,3 % |
| gender | Male | 562 | 27,6 % | 49,9 % | 42,9 % | 45,2 % | 49,5 % |
| SeniorCitizen | No | 936 | 23,4 % | 83,1 % | 67,3 % | 48,4 % | 44,7 % |
| SeniorCitizen | Yes | 191 | 41,9 % | 16,9 % | 32,7 % | 66,2 % | 65,8 % |
| Partner | No | 574 | 31,4 % | 50,9 % | 67,3 % | 58,3 % | 55,6 % |
| Partner | Yes | 553 | 21,5 % | 49,1 % | 32,7 % | 45,4 % | 39,6 % |
| Dependents | No | 799 | 30,2 % | 70,9 % | 87,6 % | 57,7 % | 55,0 % |
| Dependents | Yes | 328 | 17,7 % | 29,1 % | 12,4 % | 34,5 % | 24,4 % |

Tabla C1. Test: 1.127 clientes. OOF: predicciones out-of-fold de la CV sobre 4.507 clientes. Una diferencia de tasa real entre grupos no prueba ausencia de sesgo.

## Anexo D. Reproducibilidad y fuentes

**Repositorio:** https://github.com/jgrozo660/Proyecto-Final-AnalisisDeDatos-UTN. Contiene *proyecto_integrador.ipynb* (ejecutado de punta a punta, con salidas), *requirements.txt*, *data_log.md*, *README.md* y la carpeta *results/* con todas las tablas y figuras de este informe, además de las predicciones sobre test.csv.

### Referencias


- Kaggle. *Predicción de fuga de cliente* [competencia]. https://www.kaggle.com/competitions/prediccion-de-fuga-de-cliente

- IBM. *Telco Customer Churn* [dataset de muestra].
- Chapman, P. et al. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS.
- Chawla, N. et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16.
- Lundberg, S. y Lee, S.-I. (2017). A unified approach to interpreting model predictions. *NeurIPS 30*.
- Ley 25.326 de Protección de los Datos Personales (Argentina).