Diplomado en Ciencia de Datos y Análisis Avanzado

UTN.BA · Unidad 9 · Proyecto Final Integrador

Informe Final

Priorización de acciones de retención: predicción de abandono (churn) de clientes en una empresa de telecomunicaciones

Integrantes

Agustín Bilche Braga

Agustina Díaz

Carlos Grozo

Milagros Crespo

Luana Zalcman

Octubre de 2026

Índice

- 1. Resumen ejecutivo
- 2. Definición del problema y relevancia
- 3. Datos y metodología
- 4. Modelado y evaluación
- 5. Interpretación del modelo
- 6. Impacto en el negocio, riesgos y ética
- 7. Conclusiones y recomendaciones
- Anexos: A. Trazabilidad con la consigna, la pre-entrega y la devolución · B. Lift por deciles · C. Auditoría por grupos · D. Reproducibilidad y fuentes

1. Resumen ejecutivo

Problema. Una empresa de telecomunicaciones pierde a cerca de 1 de cada 4 clientes de su cartera: la **tasa de churn observada en la muestra** es 26,5 %. El área de Retención puede contactar aproximadamente al 20 % de la cartera por campaña y hoy no tiene un criterio para elegir a quién.

Solución. Un modelo de Regresión Logística que ordena a los clientes por riesgo estimado de abandono, para que el cupo de contactos se use primero con quienes tienen mayor score. Se compararon cinco variantes (incluidos Random Forest y Gradient Boosting) y quedaron estadísticamente empatadas; una regla definida antes de mirar el test elige la más simple e interpretable.

Indicador (test interno, 1.127 clientes)	Contacto al azar	Modelo
Abandonos detectados contactando al 20 % de mayor riesgo	20,1 %	**53,2 %**
Precisión dentro del 20 % contactado	26,6 %	70,4 %
PR-AUC (piso = tasa de churn 0,265)	0,270	0,666 (×2,5)
Beneficio neto anual estimado por 10.000 clientes*	USD 116.848	USD 392.907

Tabla 1. Resultados principales. *Escenario paramétrico con supuestos explícitos (sección 6), no costos reales de la empresa.

Resultado. Contactando al 20 % mejor rankeado se detecta el **53,2 %** de los clientes que realmente abandonan, 2,65 veces más que al azar (IC 95 %: 49,2 % a 57,9 %). Con una tasa de 26,5 %, contactar al 20 % permite detectar como máximo el 75 %. La meta definida antes de entrenar era 55 % (mínimo aceptable 50 %): **se cumple el mínimo pero no la meta**.

Qué explica el riesgo. La antigüedad es la variable más influyente (los primeros seis meses concentran el abandono), seguida por el contrato mes a mes, la fibra óptica y la falta de servicios de soporte.

Recomendación. Usar el ranking como herramienta de priorización con intervención humana y validarlo con un **piloto A/B** (20 % priorizado por el modelo contra 20 % al azar) antes de escalarlo, midiendo la tasa real de retención.

2. Definición del problema y relevancia

La pregunta de negocio no es "quién se va a ir con certeza", sino **a quién contactar primero** con un cupo limitado de llamadas e incentivos. Por eso el producto es un ranking de riesgo y no solo una clasificación sí/no. Retener a un cliente suele costar menos que adquirir uno nuevo, y cada contacto a un cliente que no iba a irse es capacidad perdida.

Objetivo medible (definido antes de correr los modelos de esta entrega): detectar ≥ 55 % de los abandonos contactando al 20 % de la cartera (mínimo aceptable 50 %). **Benchmark:** un orden aleatorio detecta ~20 %. **Techo:** 0,20 / 0,265 ≈ 75 %.

Situación	Lectura estadística	Costo de negocio
Cliente contactado que no iba a irse	Falso positivo dentro del cupo	Consume un contacto y, si hay incentivo, un descuento innecesario.
Cliente que se va y quedó fuera del 20 %	Falso negativo operativo	Se pierde su facturación futura.
Predecir siempre "no abandona"	Accuracy ≈ 73,5 %	Parece aceptable, pero no prioriza a nadie.

Tabla 2. Costo de cada tipo de error.

Hipótesis (de la pre-entrega):

- **H1:** el contrato mes a mes concentra más abandono que los contratos de 1 o 2 años.
- **H2:** a menor antigüedad, mayor abandono.
- **H3:** no tener TechSupport u OnlineSecurity y pagar con Electronic check se asocian a más abandono.
- **H4:** cargos mensuales más altos se asocian a más abandono.

3. Datos y metodología

Fuente. Competencia de Kaggle *Predicción de fuga de cliente* (kaggle.com/competitions/prediccion-de-fuga-de-cliente), basada en el dataset Telco Customer Churn. **train.csv**: 5.634 clientes y 21 columnas (perfil, servicios contratados, contrato, facturación y *Churn*). **test.csv**: 1.409 clientes sin *Churn*, usados solo para generar predicciones. El dataset es una foto estática: no tiene fechas, por lo que no se puede hablar de una tasa mensual ni hacer validación temporal.

Hallazgo de calidad	Decisión y motivo
0 nulos explícitos, pero los 8 clientes con *tenure* = 0 traen *TotalCharges* = 1.397,475 (la mediana)	**Corregido a 0**: el archivo venía pre-imputado. Un cliente sin meses facturados no acumuló cargos. La pre-entrega había reportado "sin nulos".
15 filas idénticas salvo el *customerID*	Se conservan: son clientes distintos con el mismo perfil.
TotalCharges ≈ *tenure* × *MonthlyCharges* (mediana del cociente 1,00)	Se descarta el "cargo promedio por mes" pendiente de la pre-entrega: repetiría *MonthlyCharges*.
Servicios adicionales dispersos en 6 columnas	Se agrega *n_servicios* (0-6) como resumen del "enganche" del cliente.
Desbalance: 26,5 % abandona	Métricas de ranking (Recall @ 20 %, PR-AUC); accuracy solo como referencia.

Tabla 3. Calidad de datos y decisiones (detalle en data_log.md).

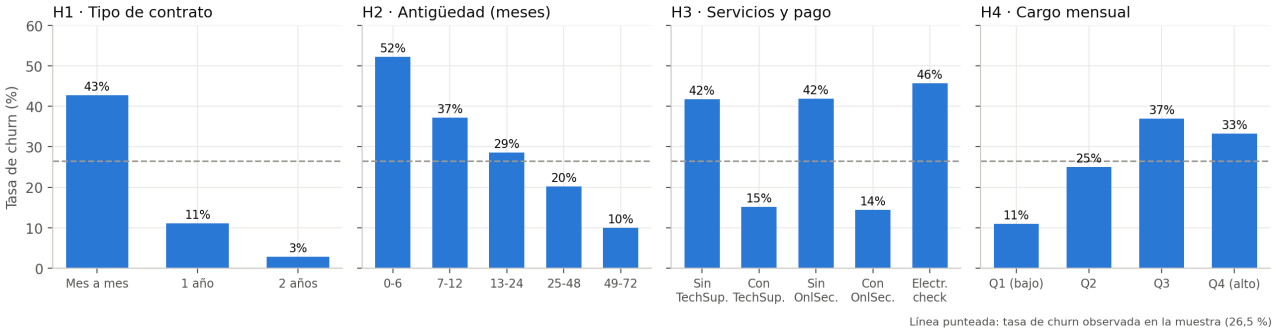


Figura 1. Tasa de churn por contrato (H1), antigüedad (H2), servicios y forma de pago (H3) y cuartil de cargo mensual (H4). Línea punteada: tasa observada en la muestra.

Conclusiones del EDA.

- **H1:** el contrato mes a mes abandona 42,7 %, contra 11,1 % (1 año) y 2,9 % (2 años).
- **H2:** el abandono es 52,2 % en los primeros seis meses y baja de forma monótona hasta 9,9 % después de los cuatro años.
- **H3:** sin TechSupport u OnlineSecurity la tasa ronda 42 %, contra 14-15 % con el servicio; Electronic check llega a 45,7 %.
- **H4:** el abandono crece del cuartil más bajo (10,9 %) al tercero (37,0 %), pero baja levemente en el más alto (33,3 %).
- Contrato, antigüedad y cargos están relacionados entre sí: el EDA es descriptivo y el aporte propio de cada bloque se mide con ablaciones (sección 5).

Metodología. Se siguió CRISP-DM: negocio (sección 2), comprensión y preparación de datos (sección 3), modelado y evaluación (sección 4) y traducción a una decisión (secciones 5-6). Todo el preprocesamiento (One-Hot para categóricas, escalado para numéricas) vive dentro de un *Pipeline* que se ajusta solo con datos de entrenamiento, con *random_state* = 42 y las decisiones registradas en *data_log.md*.

Diseño de validación	Pregunta que responde
CV estratificada de 5 folds sobre el 80 % de desarrollo	¿Qué modelo ordena mejor? Define el candidato.
Test estratificado 20 % (misma partición que la pre-entrega), usado una sola vez	¿Cuánto rinde con clientes no vistos?
Bootstrap del test (2.000 remuestreos)	¿Las diferencias entre modelos son mayores que el ruido?
Predicciones out-of-fold del desarrollo	Elegir el umbral sí/no y repetir la auditoría ética sin usar el test.

Tabla 4. Diseño de validación. No hay validación temporal porque los datos no tienen fechas.

4. Modelado y evaluación

Siguiendo la devolución de la pre-entrega, el baseline se comparó con Random Forest y Gradient Boosting. Cada variante responde una pregunta concreta: la logística **balanceada** es el baseline de la pre-entrega; la **sin ponderar** mide si la ponderación cambia el ranking o solo el umbral; la variante con **SMOTE** mide si sobremuestrear ayuda (SMOTE vive dentro de un *imblearn.Pipeline*, así que solo se aplica sobre los datos de entrenamiento de cada fold); Random Forest (500 árboles, hoja mínima 5) y Gradient Boosting (300 árboles, profundidad 3) miden si un modelo no lineal captura algo más.

Regla de selección definida antes de ver el test: los modelos a menos de un desvío estándar de la mejor PR-AUC media en CV se consideran empatados; entre empatados se elige el más simple (logística sin ponderar → balanceada → SMOTE → Random Forest → Gradient Boosting).

Modelo	PR-AUC CV (media ± desvío)	ROC-AUC CV	Recall @ 20 % CV
Logística sin ponderar	**0,659 ± 0,023**	**0,844**	**50,4 %**
Logística + SMOTE (solo train)	0,659 ± 0,024	0,844	49,8 %
Logística balanceada (pre-entrega)	0,657 ± 0,024	0,843	50,1 %
Random Forest	0,657 ± 0,031	0,843	50,1 %
Gradient Boosting	0,653 ± 0,043	0,839	48,6 %

Tabla 5. Validación cruzada de 5 folds sobre 4.507 clientes. Umbral de empate: 0,636. Los cinco modelos quedan empatados.

Los cinco modelos quedan dentro del margen de empate (PR-AUC entre 0,653 y 0,659, con desvíos de 0,02 a 0,04). La regla elige la **Regresión Logística sin ponderar**. Dos lecturas: la ponderación de clases y SMOTE no cambian el ranking (solo mueven el umbral), y los árboles no encuentran interacciones que la logística no capture.

Modelo (test)	PR-AUC	ROC-AUC	Recall @ 20 %	Precisión @ 20 %	Lift @ 20 %	Brier
Ranking aleatorio	0,270	0,500	20,1 %	26,6 %	1,00	-
Logística sin ponderar	**0,666**	**0,848**	**53,2 %**	**70,4 %**	**2,65**	**0,133**
Logística + SMOTE (solo train)	0,667	0,849	53,5 %	70,8 %	2,67	0,159
Logística balanceada (pre-entrega)	0,666	0,848	53,2 %	70,4 %	2,65	0,163
Random Forest	0,655	0,847	51,5 %	68,1 %	2,57	0,134
Gradient Boosting	0,673	0,853	52,8 %	69,9 %	2,64	0,132

Tabla 6. Evaluación única sobre el 20 % de test (1.127 clientes, 299 abandonos). Brier: error de las probabilidades (menor es mejor).

En el test, Gradient Boosting obtiene la PR-AUC más alta (0,673 contra 0,666), pero la diferencia no es significativa: el intervalo de 95 % por bootstrap de la diferencia va de -0,034 a +0,018, y en Recall @ 20 % de -2,3 a +3,6 puntos. Coincide con la CV: no hay un ganador claro, y la regla ex ante no se cambia por el resultado del test.

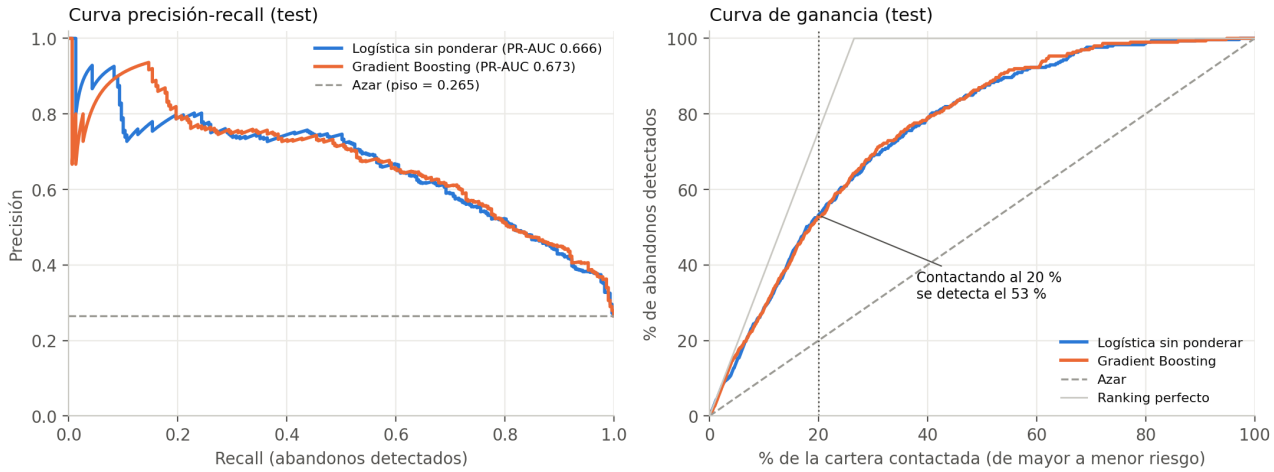


Figura 2. Curva precisión-recall y curva de ganancia en el test. Línea vertical punteada: cupo de 20 %. Las curvas de la logística y de Gradient Boosting prácticamente se superponen.

% de la cartera contactada	Abandonos detectados	Precisión	Lift
10 %	28,8 %	76,1 %	2,87
20 %	**53,2 %**	**70,4 %**	**2,65**
30 %	68,9 %	60,8 %	2,29
40 %	78,9 %	52,3 %	1,97
50 %	87,0 %	46,1 %	1,74

Tabla 7. Abandonos detectados según el porcentaje de la cartera contactada (modelo elegido, test).

Calibración y umbral. La ponderación de clases y SMOTE inflan las probabilidades: la logística balanceada de la pre-entrega tiene Brier 0,163 contra 0,133 de la sin ponderar, cuya curva de calibración sigue de cerca la diagonal. Por eso el score del modelo elegido puede leerse como una probabilidad aproximada. Si se necesita una etiqueta sí/no (por ejemplo, para la competencia), el umbral se eligió maximizando F1 con las predicciones

out-of-fold del desarrollo, sin mirar el test: 0,328. Con él, en el test se detecta el 72,6 % de los abandonos con precisión 56,7 % (F1 0,636), marcando como riesgo al 34,0 % de los clientes.

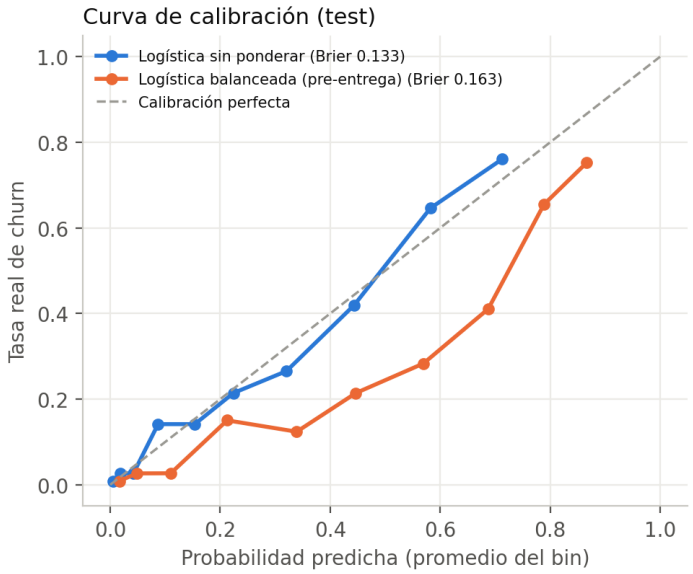


Figura 3. Curva de calibración en el test: logística sin ponderar (azul) contra la balanceada de la pre-entrega (naranja).

5. Interpretación del modelo

Se usó SHAP (*LinearExplainer*) sobre los 1.127 clientes del test. Las columnas One-Hot se sumaron por variable original, así el negocio lee "Contract" y no tres columnas. En una regresión logística SHAP se expresa en log-odds: el signo indica si la variable sube o baja el riesgo y la magnitud cuánto lo mueve. **SHAP describe cómo razona el modelo; no demuestra causalidad.**

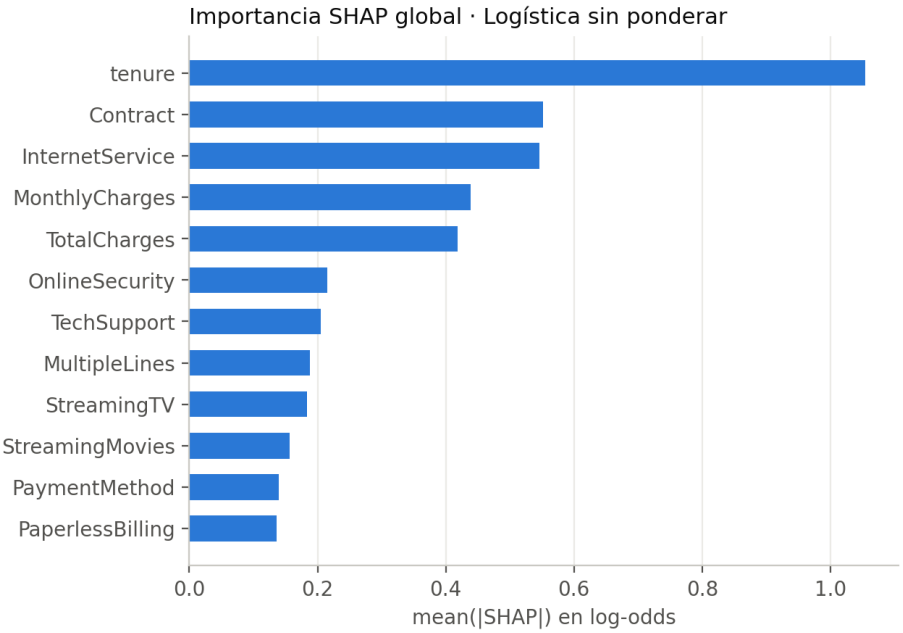


Figura 4. Importancia SHAP global agrupada por variable original (top 12).

La **antigüedad** es, por lejos, la variable más influyente (mean|SHAP| 1,05), seguida por el **contrato** (0,55) y el **tipo de internet** (0,55). En dirección: el tercio de clientes más nuevos suma en promedio +1,35 log-odds y el más antiguo –1,40; el contrato mes a mes suma +0,49 y el de dos años resta 1,00; la fibra óptica suma +0,53. No tener TechSupport u OnlineSecurity suma entre +0,15 y +0,18.

Cautela con *MonthlyCharges*. En el EDA los cargos altos se asocian a más abandono, pero dentro del modelo su efecto es negativo: a igualdad de servicios contratados, un cargo más alto no suma riesgo. La razón es la colinealidad: la fibra óptica y el streaming ya explican por qué esos clientes pagan más. Por eso H4 no se sostiene por encima de los servicios.

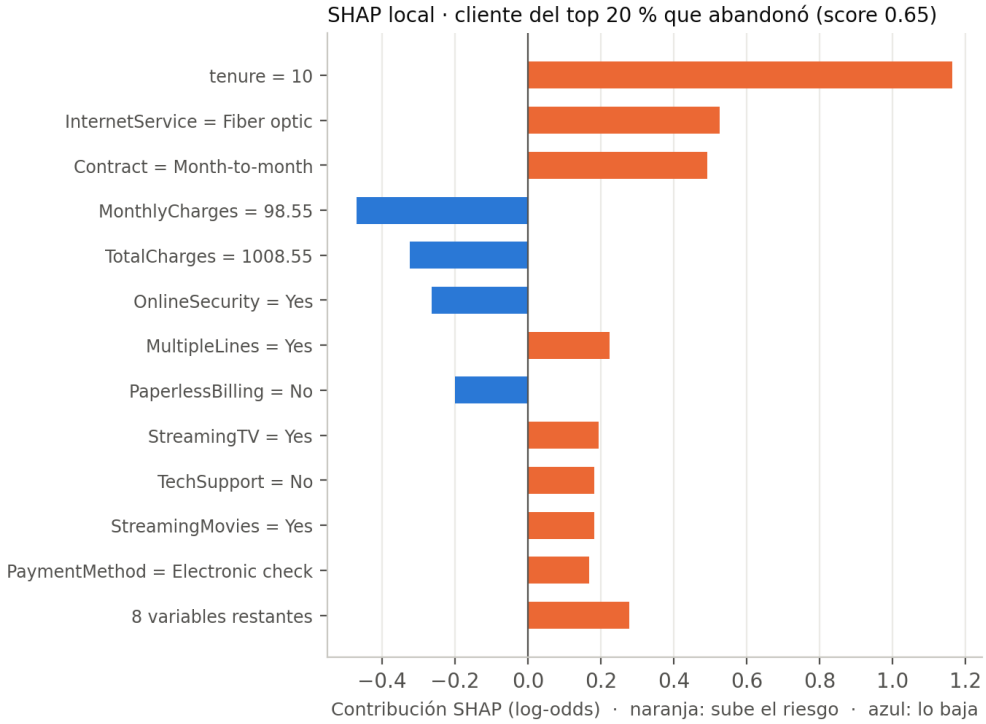


Figura 5. SHAP local de un cliente real del test que abandonó y quedó dentro del 20 % priorizado.

Caso local. La explicación parte del valor base del modelo (–1,52 log-odds, unos 18 % de probabilidad) y llega a un score de 0,65. Diez meses de antigüedad (+1,16), fibra óptica (+0,53) y contrato mes a mes (+0,49) empujan el riesgo hacia arriba; tener OnlineSecurity lo baja (–0,26). Para Retención la lectura es accionable: es un cliente nuevo, sin compromiso de permanencia y con un servicio de alto costo, candidato a una oferta de migración a contrato anual.

Ablación sobre el mismo test	PR-AUC	Cambio en PR-AUC	Cambio en Recall @ 20 %	Lectura
Modelo completo	0,666	-	-	Referencia
H1: sin Contract	0,663	-0,3 p.p.	+0,3 p.p.	Casi sin caída: la antigüedad cuenta la misma historia.
H2: sin antigüedad (tenure, TotalCharges)	0,609	-5,7 p.p.	-4,7 p.p.	**Mayor caída individual.** H2 respaldada.
H3: sin servicios de soporte y forma de pago	0,660	-0,6 p.p.	+0,3 p.p.	Caída pequeña: otras variables los sustituyen.
H4: sin MonthlyCharges	0,667	+0,1 p.p.	0,0 p.p.	Sin caída: H4 no aporta por encima de los servicios.
Contrato + antigüedad juntos	0,590	-7,6 p.p.	-5,7 p.p.	**La caída más grande**: H1 y H2 juntas son el núcleo de la señal.

Tabla 8. Ablaciones: se reentrena el mismo pipeline sin cada bloque. Con 299 abandonos en el test, cambios menores a ~1-2 puntos están dentro del ruido.

Veredicto de las hipótesis. H2 queda respaldada por el EDA, por SHAP y por la ablación. H1 se respalda en el EDA y en SHAP, pero su aporte se superpone con la antigüedad: quitar ambas juntas baja la PR-AUC 7,6 puntos. H3 tiene respaldo descriptivo y un aporte propio pequeño. H4 no se sostiene una vez que se conocen los servicios contratados.

6. Impacto en el negocio, riesgos y ética

Escenario económico. No se cuenta con costos reales de la empresa, por lo que se usan supuestos explícitos para que el área los reemplace: USD 15 por cliente contactado (llamada + incentivo), 30 % de éxito de la acción sobre un cliente que iba a irse, y como valor de un cliente retenido su *MonthlyCharges* real × 12 meses. Se calcula sobre el test y se escala a una cartera de 10.000 clientes.

Escenario (10.000 clientes)	Contactos	Abandonos detectados	Retenidos esperados	Ingreso anual preservado	Beneficio neto
Modelo: top 20 %	2.005	1.411	423	USD 422.987	USD 392.907
Azar: 20 % aleatorio	2.005	532	160	USD 146.927	USD 116.848
Diferencia	**0**	**879**	**264**	**USD 276.060**	**USD 276.060**

Tabla 9. Escenario económico paramétrico con el recall medido en el test.

Con el mismo presupuesto de contactos, el modelo detecta unos 879 abandonos más que el azar y agrega cerca de USD 276 mil de beneficio neto anual por cada 10.000 clientes. El monto depende fuertemente de la tasa de éxito: con 15 % el beneficio del modelo cae a USD 181 mil y con 45 % sube a USD 604 mil (ver results/sensibilidad_economica.csv). Esa tasa es justamente lo que el piloto debe medir.

Iniciativas de retención según el perfil de riesgo. El ranking dice a quién contactar; SHAP sugiere qué ofrecer:

Perfil dentro del 20 % priorizado	Acción sugerida
Cliente nuevo (primeros 6-12 meses) con contrato mes a mes	Oferta de migración a contrato anual con beneficio de bienvenida (descuento o upgrade temporal).
Fibra óptica sin TechSupport ni OnlineSecurity	Incluir soporte técnico o seguridad online sin costo por un período, para aumentar el enganche.
Pago con Electronic check	Incentivo para pasar a débito automático (transferencia o tarjeta).
Score alto en cualquier perfil	Contacto proactivo del equipo de Retención antes del vencimiento de la factura.

Tabla 10. Acciones a validar en el piloto: son hipótesis de negocio derivadas del modelo, no efectos causales probados.

Auditoría ética. Se auditó el ranking por género, edad (*SeniorCitizen*), pareja y dependientes (detalle en el Anexo C). En el test aparece una brecha de recall por género (61,8 % en mujeres contra 45,2 % en hombres; IC 95 % de la diferencia: 5,1 a 28,3 puntos), aunque ambos grupos abandonan a tasas parecidas. Sin embargo, la misma auditoría sobre las predicciones out-of-fold de 4.507 clientes no la reproduce (50,3 % contra 49,5 %): la brecha es propia de esa muestra de test y no un patrón sistemático. Los adultos mayores (tasa real 41 %) ocupan más lugares en el top 20 %, coherente con su mayor abandono. Los clientes **con dependientes** quedan sub-detectados de forma consistente (recall 24-34 % contra 55-58 %): abandonan menos, pero cuando lo hacen el modelo los ve menos. Quitar *gender* y *SeniorCitizen* no cambia el desempeño (PR-AUC 0,664 contra 0,666), por lo que se recomienda excluirlos en producción.

Riesgo	Mitigación
Datos estáticos, sin fechas: no se sabe si el patrón se mantiene en el tiempo	Reentrenar periódicamente y monitorear Recall @ 20 % y la distribución de las variables.
Diferencias de recall entre grupos (dependientes; brecha de género en test)	Auditoría por grupo en cada campaña; excluir atributos sensibles que no aportan.
Profecía autocumplida: solo se observa la retención de quienes se contactan	Reservar un grupo de control aleatorio (el piloto A/B) en cada campaña.
Supuestos económicos no validados	Medir costo real por contacto y tasa de éxito en el piloto antes de escalar.
Privacidad de datos de clientes	Minimización de datos, control de accesos y cumplimiento de la Ley 25.326 de Protección de Datos Personales.

Tabla 11. Riesgos y mitigaciones.

Escalabilidad. El pipeline entrena en segundos y puntúa la cartera completa al instante; puede ejecutarse antes de cada campaña y extenderse a otros productos cambiando la variable objetivo y repitiendo la auditoría.

7. Conclusiones y recomendaciones

- El problema se formuló como priorización bajo un cupo de contactos: Recall @ 20 % y PR-AUC reflejan la decisión mejor que accuracy.
- Contactando al 20 % de mayor riesgo, el modelo detecta el 53,2 % de los abandonos (2,65 veces el azar). Cumple el mínimo de 50 % pero no la meta de 55 %.
- Random Forest, Gradient Boosting, SMOTE y la ponderación de clases no mejoran el ranking de la Regresión Logística: se elige el modelo más simple, interpretable y mejor calibrado.
- La antigüedad y el tipo de contrato son el núcleo de la señal; el riesgo se concentra en clientes nuevos, con contrato mes a mes, fibra óptica y sin servicios de soporte.
- El valor económico es positivo bajo supuestos razonables, pero depende de la tasa de éxito de la acción de retención, que todavía no se conoce.

Recomendación. No desplegar de forma automática. Ejecutar un piloto A/B con el mismo presupuesto (20 % priorizado por el modelo contra 20 % al azar), medir retención real, costo por cliente retenido y Recall @ 20 % por grupo, excluir *gender* y *SeniorCitizen* del modelo, y escalar solo si el piloto confirma el beneficio. Como acción de negocio inmediata, los hallazgos sugieren campañas de migración de contrato mensual a anual en los primeros meses de vida del cliente y la oferta de TechSupport/OnlineSecurity a clientes de fibra óptica.

Próximos pasos. Incorporar variables de interacción con el cliente (reclamos, llamadas al soporte) y datos con fecha, que permitirían validar el modelo hacia adelante en el tiempo.

Anexo A. Trazabilidad con la consigna, la pre-entrega y la devolución

Peso	Criterio de evaluación	Evidencia en el informe
20 %	Problema y alineación con negocio	Secciones 1-2: decisión, objetivo ex ante, benchmark, techo y costo del error.
20 %	Datos, metodología y justificación técnica	Sección 3: calidad con cifras (centinela de TotalCharges), CRISP-DM, diseño de validación.
15 %	Selección y defensa del modelo	Sección 4: CV, regla ex ante, empate, bootstrap (Tablas 5-6).
15 %	Calidad de las métricas	PR-AUC con piso, Recall/Precisión/Lift @ 20 %, captura por cupo, calibración, deciles.
15 %	Interpretación y cuantificación de valor	Sección 5 (SHAP, ablaciones) y sección 6 (escenario económico y sensibilidad).
5 %	Ética y privacidad	Sección 6 y Anexo C: auditoría por grupos en test y OOF, modelo sin atributos sensibles.
10 %	Impacto y claridad	Resumen en lenguaje no técnico, figuras y recomendación proporcional a la evidencia.

Tabla A1. Criterios de evaluación (pesos del modelo de informe de la cátedra) y dónde se cubren.

Devolución del tutor	Estado en la entrega final
Usar "tasa de churn observada en la muestra" en lugar de "mensual"	Aplicado en todo el informe y el repositorio.
Comparar el baseline con Random Forest o Gradient Boosting, sin modelos de relleno	Se comparan ambos; cada variante responde una pregunta (sección 4).
Incorporar PR-AUC además de Recall y ROC-AUC	PR-AUC es la métrica técnica principal, siempre junto a su piso.
Traducir a negocio: contactando al 20 %, ¿qué % de abandonos se detecta?	53,2 % (Tabla 7, Figura 2).
Si se usa SMOTE, solo sobre entrenamiento	SMOTE dentro de un imblearn.Pipeline por fold; no mejora el ranking.

Tabla A2. Devolución del tutor sobre la pre-entrega y cómo se resolvió.

Comprometido en la pre-entrega	Estado en la entrega final
Dataset de Kaggle y limpieza tomada	Aplicado; se detectó y corrigió el centinela de TotalCharges.
Pendiente: variables derivadas	Cargo promedio por mes descartado (redundante); se agregó n_servicios.
Probar Random Forest y Gradient Boosting	Hecho (Tablas 5-6).
Explorar SMOTE y ajuste de umbral	Hecho: SMOTE no mejora; umbral elegido con OOF (sección 4).
Predicciones sobre test.csv y cuantificación de impacto	results/predicciones_test.csv y sección 6.
Meta de la pre-entrega: Recall ≥ 0,75 y ROC-AUC ≥ 0,80 con umbral 0,5	Reformulada como ranking por la devolución. Con el umbral OOF: recall 72,6 %; ROC-AUC 0,848.

Tabla A3. Compromisos de la pre-entrega y su estado.

Métrica (mismo test interno)	Pre-entrega: logística balanceada, umbral 0,5	Entrega final: logística sin ponderar
ROC-AUC	0,848	0,848
PR-AUC	no reportada	0,666
Abandonos detectados contactando al 20 %	no reportado	53,2 %
Recall con umbral de decisión	79,9 % (umbral 0,5)	72,6 % (umbral 0,328)
Precisión con umbral de decisión	52,4 %	56,7 %
F1	0,633	0,636
Brier (calidad de las probabilidades)	0,163	0,133

Tabla A4. Pre-entrega contra entrega final. La capacidad de ordenar (ROC-AUC) es la misma; lo que mejora es cómo se mide y se usa: ranking con cupo, PR-AUC, umbral elegido sin mirar el test y probabilidades calibradas.

Anexo B. Lift por deciles (modelo elegido, test)

Decil	Clientes	Abandonos	Tasa	Lift	Recall acumulado
1	113	86	76,1 %	2,87	28,8 %
2	112	73	65,2 %	2,46	53,2 %
3	113	47	41,6 %	1,57	68,9 %
4	113	30	26,5 %	1,00	78,9 %
5	113	24	21,2 %	0,80	87,0 %
6	112	16	14,3 %	0,54	92,3 %
7	113	16	14,2 %	0,53	97,7 %
8	113	3	2,7 %	0,10	98,7 %
9	112	3	2,7 %	0,10	99,7 %
10	113	1	0,9 %	0,03	100,0 %

Tabla B1. El primer decil abandona 76,1 % (lift 2,87); los dos primeros deciles concentran el 53,2 % de los abandonos.

Anexo C. Auditoría por grupos (top 20 %)

Atributo	Grupo	Clientes	Tasa real	% de la cartera	% del top 20	Recall (test)	Recall (OOF)
gender	Female	565	25,5 %	50,1 %	57,1 %	61,8 %	50,3 %
gender	Male	562	27,6 %	49,9 %	42,9 %	45,2 %	49,5 %
SeniorCitizen	No	936	23,4 %	83,1 %	67,3 %	48,4 %	44,7 %
SeniorCitizen	Yes	191	41,9 %	16,9 %	32,7 %	66,2 %	65,8 %
Partner	No	574	31,4 %	50,9 %	67,3 %	58,3 %	55,6 %
Partner	Yes	553	21,5 %	49,1 %	32,7 %	45,4 %	39,6 %
Dependents	No	799	30,2 %	70,9 %	87,6 %	57,7 %	55,0 %
Dependents	Yes	328	17,7 %	29,1 %	12,4 %	34,5 %	24,4 %

Tabla C1. Test: 1.127 clientes. OOF: predicciones out-of-fold de la CV sobre 4.507 clientes. Una diferencia de tasa real entre grupos no prueba ausencia de sesgo.

Anexo D. Reproducibilidad y fuentes

Repositorio: https://github.com/jgrozo660/Proyecto-Final-AnalisisDeDatos-UTN. Contiene *proyecto_integrador.ipynb* (ejecutado de punta a punta, con salidas), *requirements.txt*, *data_log.md*, *README.md* y la carpeta *results/* con todas las tablas y figuras de este informe, además de las predicciones sobre test.csv.

Referencias

- Kaggle. *Predicción de fuga de cliente* [competencia]. https://www.kaggle.com/competitions/prediccion-de-fuga-de-cliente
- IBM. *Telco Customer Churn* [dataset de muestra].
- Chapman, P. et al. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS.
- Chawla, N. et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16.
- Lundberg, S. y Lee, S.-I. (2017). A unified approach to interpreting model predictions. *NeurIPS 30*.
- Ley 25.326 de Protección de los Datos Personales (Argentina).