Diplomado en Ciencia de Datos y Análisis Avanzado

# Pre-entrega - Proyecto Final Integrador

Predicción de abandono de clientes (Churn) en una empresa de telecomunicaciones


**Integrantes:**

Agustín Bilche Braga

Agustina Díaz

Carlos Grozo

Milagros Crespo

Luana Zalcman


Septiembre de 2026

# 1. Resumen ejecutivo

Este proyecto aborda la predicción de abandono (churn) de clientes en una empresa de telecomunicaciones. La audiencia interna son las áreas de Retención y Marketing, que necesitan anticipar qué clientes probablemente den de baja el servicio para actuar a tiempo. El KPI principal es la **tasa de churn mensual** (~26,5% en la base analizada); el objetivo del modelo es maximizar el **Recall** sobre la clase "abandona", dado el desbalance de clases y el costo asimétrico de no detectar una baja.

# 2. Definición del problema y caso de negocio

## Objetivo medible

Construir un modelo de clasificación binaria que, a partir de datos contractuales, de uso de servicios y de facturación, prediga si un cliente abandonará el servicio (Churn = Sí/No). Meta: Recall ≥ 75% sobre la clase minoritaria y ROC AUC ≥ 0,80.

## Hipótesis de trabajo

A partir de un primer análisis exploratorio se plantean las siguientes hipótesis, que orientarán el modelado:

- Contrato mes a mes → mayor abandono que contratos de 1 o 2 años.
- Menor antigüedad (tenure) → mayor probabilidad de abandono.
- Ausencia de TechSupport/OnlineSecurity y pago por Electronic check se asocian a mayor churn.
- Cargos mensuales (MonthlyCharges) altos se asocian a mayor abandono.

## Restricciones conocidas

- Snapshot histórico puntual, sin estacionalidad ni cambios comerciales recientes; sin datos de interacciones con atención al cliente ni contexto externo.
- Desbalance moderado en la variable objetivo (~73,5% / 26,5%), que exige métricas y estrategias específicas.
- El dataset de test no incluye Churn, por lo que la validación se realiza sobre la partición de entrenamiento.

## Valor esperado

Anticipar clientes en riesgo permite diseñar campañas de retención focalizadas antes de la baja. Retener cuesta menos que adquirir un cliente nuevo, por lo que incluso una reducción moderada en la tasa de churn representa un ahorro sostenido.

# 3. Relevamiento de fuentes de datos a utilizar

## Fuente y tamaño

Datos de la competencia pública de Kaggle "Predicción de fuga de cliente" (kaggle.com/competitions/prediccion-de-fuga-de-cliente). **train.csv**: 5.634 registros, 21 columnas (incluye Churn). **test.csv**: 1.409 registros, 20 columnas (sin Churn). Sin restricciones de licencia para uso académico.

## Diccionario de las 10 variables principales

| Variable | Tipo | Descripción |
|---|---|---|
| Churn | Categórica (objetivo) | Indica si el cliente abandonó el servicio (Sí/No). |
| tenure | Numérica | Antigüedad del cliente en meses (0 a 72). |
| Contract | Categórica | Tipo de contrato: mes a mes, un año o dos años. |
| MonthlyCharges | Numérica | Cargo mensual facturado al cliente (18,40 a 118,75). |
| TotalCharges | Numérica | Cargo total acumulado por el cliente durante su permanencia. |
| InternetService | Categórica | Tipo de servicio de internet: DSL, fibra óptica o ninguno. |
| TechSupport | Categórica | Indica si el cliente cuenta con soporte técnico contratado. |
| OnlineSecurity | Categórica | Indica si el cliente cuenta con seguridad online contratada. |
| PaymentMethod | Categórica | Método de pago: transferencia, tarjeta, cheque electrónico o correo. |
| SeniorCitizen | Numérica (binaria) | Indica si el cliente es adulto mayor (1) o no (0). |

El dataset completo tiene 21 variables; a las 10 detalladas se suman gender, Partner, Dependents, PhoneService, MultipleLines, OnlineBackup, DeviceProtection, StreamingTV, StreamingMovies y PaperlessBilling (categóricas de pocas categorías), y customerID (sin valor predictivo).

## Nulos, outliers y calidad de datos

No se detectaron valores nulos en ninguna de las 21 columnas. Los boxplots de tenure y MonthlyCharges no evidenciaron outliers extremos; 20 clientes con alta antigüedad (más de 69 meses) igualmente abandonaron, interpretado como caso de negocio válido. TotalCharges presenta asimetría hacia la derecha, esperable por su dependencia de tenure y MonthlyCharges.

## Decisiones de limpieza ya tomadas / pendientes

- **Tomadas:** eliminación de customerID; pipeline con imputación (mediana/moda), escalado estándar y One-Hot para categóricas.

- **Pendientes:** variables derivadas (cargo promedio por mes) y reducción de categorías poco frecuentes.

# 4. Plan de modelado y validación

## Validación y métricas

train.csv: 80/20 (entrenamiento/validación), estratificado (stratify=y, random_state=42); test.csv se reserva para predicciones finales (no incluye Churn). Por el desbalance (~26,5%), se reportan Accuracy, Precision, Recall, F1-score y ROC AUC, priorizando Recall: el costo de no detectar una baja es mayor que contactar a un cliente que iba a permanecer.

## Baseline reproducible

Se entrenaron tres modelos sobre el mismo pipeline (ColumnTransformer con escalado y One-Hot): Regresión Logística, k-NN y Naive Bayes. Resultados de validación:

| Modelo | Accuracy | Precision | Recall | F1-Score | ROC AUC |
|---|---|---|---|---|---|
| Regresión Logística | 0,815 | 0,692 | 0,542 | 0,608 | 0,848 |
| k-NN | 0,763 | 0,556 | 0,532 | 0,544 | 0,781 |
| Naive Bayes | 0,699 | 0,463 | 0,829 | 0,594 | 0,826 |
| Regresión Logística Balanceada | 0,754 | 0,524 | 0,799 | 0,633 | 0,848 |

La Regresión Logística fue el mejor modelo base. Con class_weight="balanced", el Recall subió de 0,542 a 0,799 y el F1-score de 0,608 a 0,633, a costa de menor Precision, con ROC AUC casi constante (0,848). Queda como baseline de referencia.

## Umbrales de éxito y benchmark de negocio

- Umbral mínimo: Recall ≥ 0,75 y ROC AUC ≥ 0,80, alcanzados por el baseline balanceado (0,799 y 0,848).
- Benchmark: superar la identificación pasiva actual; se ajustará el umbral según el costo de las campañas.

## Riesgos, limitaciones y próximos pasos

- Desbalance de clases: se explorarán SMOTE y ajuste de umbral además de class_weight.
- Snapshot histórico sin variables de interacción con el cliente (reclamos, NPS); se evaluará feature engineering sobre tenure/MonthlyCharges.
- test.csv no puede validarse localmente (no incluye Churn); se probarán Random Forest/Gradient Boosting antes de las predicciones finales y la cuantificación de impacto.