¿A quién llamar primero?

Predicción de abandono (churn) de clientes en una empresa de telecomunicaciones

Grupo 4

Agustín Bilche Braga · Agustina Díaz · Carlos Grozo · Milagros Crespo · Luana Zalcman

Diplomado en Ciencia de Datos y Análisis Avanzado · UTN.BA · Unidad 10 · Proyecto Final Integrador

Octubre de 2026

1 de cada 4 clientes se va, y no se puede llamar a todos

26,5 %

de los clientes abandona el servicio (tasa de churn observada en la muestra)

20 %

de la cartera puede contactar Retención en cada campaña

La pregunta de negocio

¿A qué 20 % llamar para detectar la mayor cantidad posible de clientes que se van a ir?

Hoy ese cupo se asigna sin un criterio. Llamando al azar se detecta, en promedio, solo el 20 % de los abandonos.

Cómo trabajamos: CRISP-DM

1

Negocio

KPI: % de abandonos detectados contactando al 20 %. Meta: 55 %.

2

Datos

5.634 clientes, 21 variables. EDA y control de calidad.

3

Preparación

Pipeline sin fuga de información; variable n_servicios.

4

Modelado

5 variantes comparadas con validación cruzada de 5 folds.

5

Evaluación

Test único de 1.127 clientes + intervalos por bootstrap.

6

Negocio otra vez

Impacto económico, auditoría ética y acciones.

Todo el proceso está en un notebook reproducible (Colab + GitHub) con semilla fija y un registro de decisiones.

Los datos: limpios a primera vista, con una trampa

5.634 clientes para entrenar y evaluar

1.409 clientes a predecir (test.csv)

21 variables: perfil, servicios, contrato y facturación

"0 valores nulos"... pero no

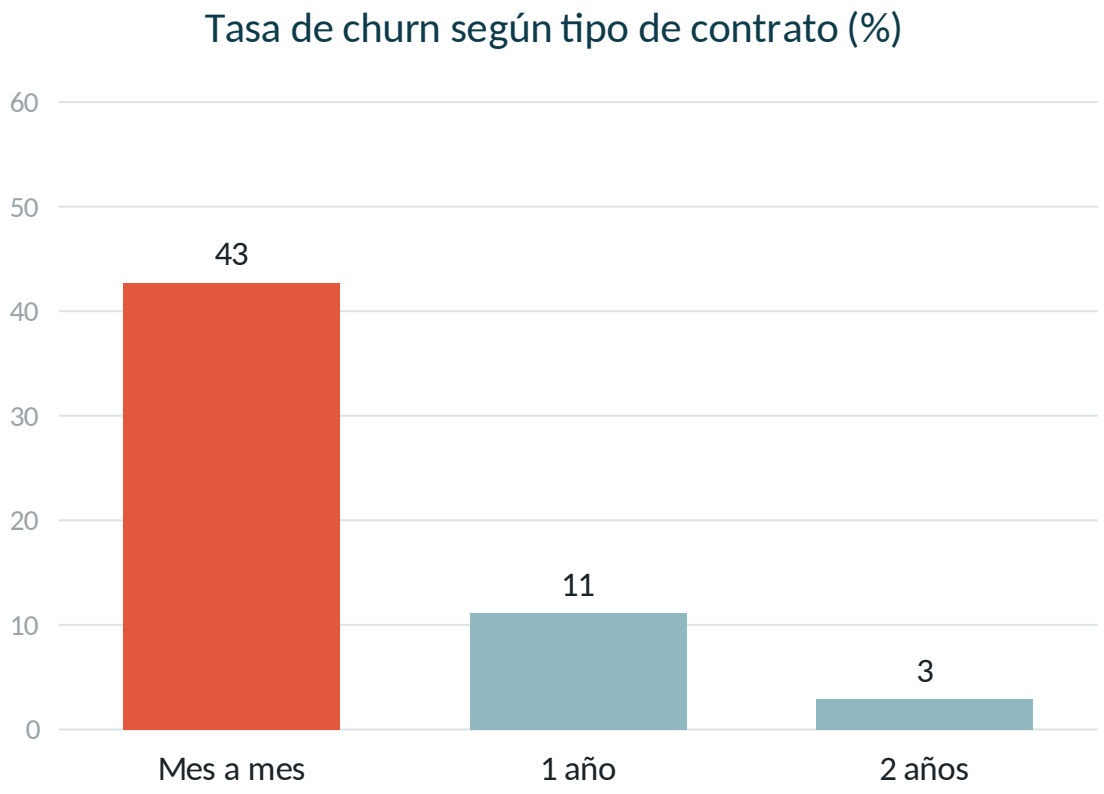
Los 8 clientes recién dados de alta (0 meses de antigüedad) tenían un cargo total de 1.397, que es exactamente la mediana de la columna: el archivo venía rellenado.

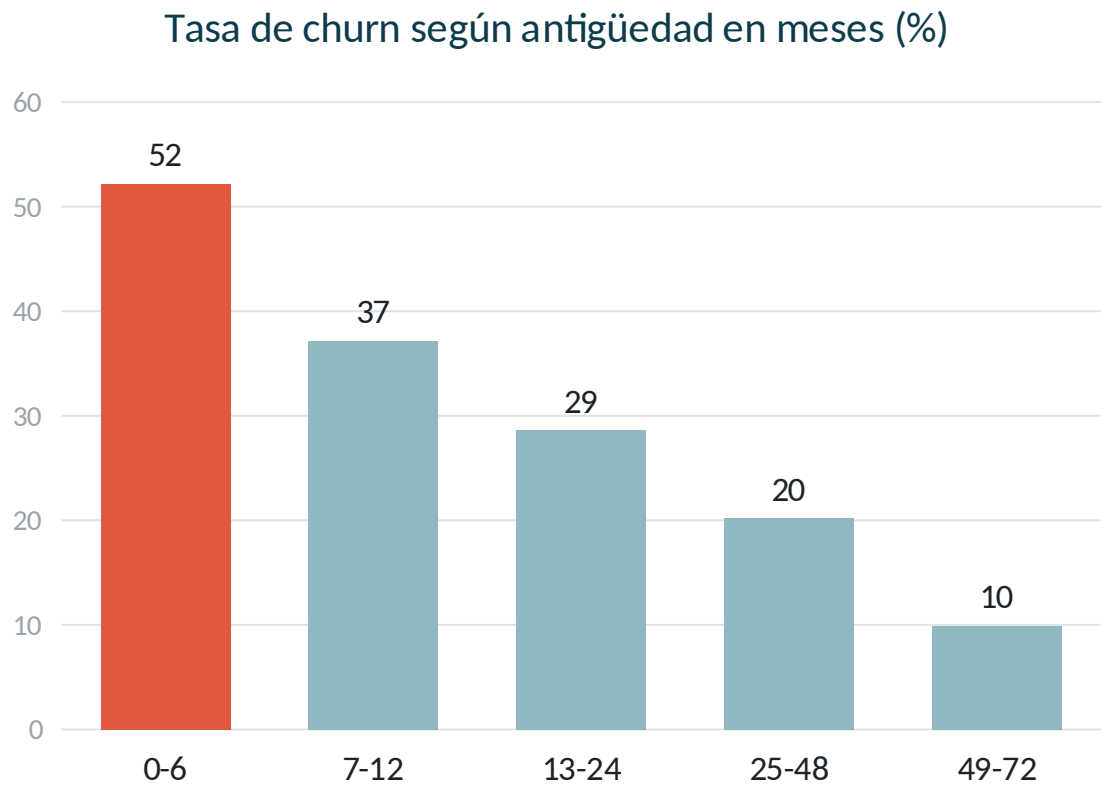
Decisión: corregirlo a 0.

Un cliente sin meses facturados no acumuló cargos. Además descartamos el "cargo promedio por mes" (repetía el cargo mensual) y agregamos la cantidad de servicios contratados.

Fuente: competencia de Kaggle "Predicción de fuga de cliente" (dataset Telco Customer Churn).

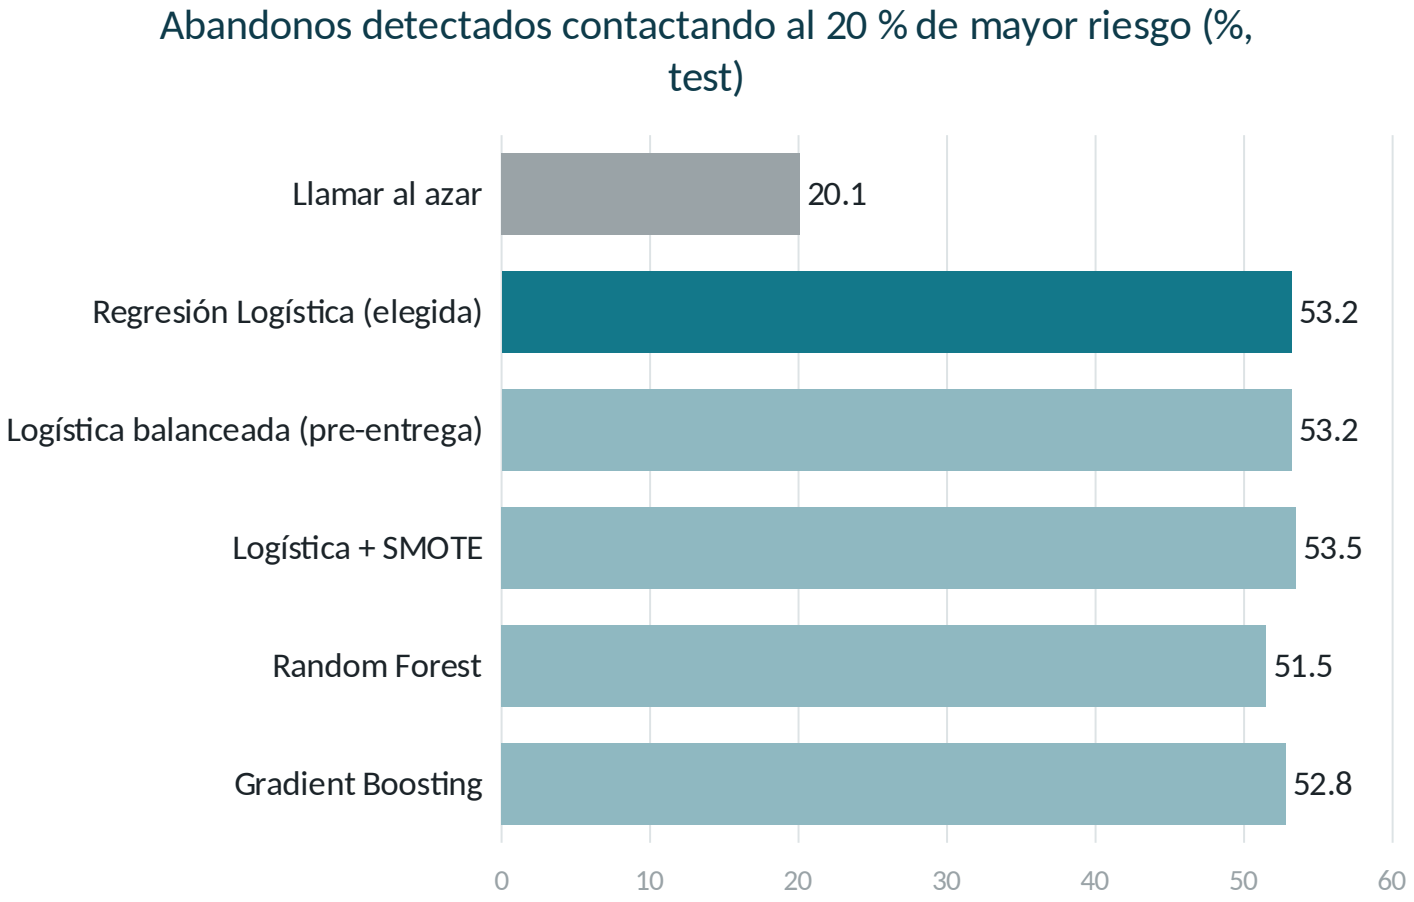
El abandono se concentra en clientes nuevos y sin compromiso





Contrato mes a mes: 43 % abandona, contra 3 % con contrato de 2 años. En los primeros 6 meses abandona más de la mitad. También suben el riesgo la fibra óptica, no tener soporte técnico y pagar con cheque electrónico.

Cinco modelos, un empate: elegimos el más simple



Empate estadístico
Los cinco quedan dentro del margen de error (validación cruzada y bootstrap).

Regla fijada de antemano
Entre empatados, el más simple: Regresión Logística.

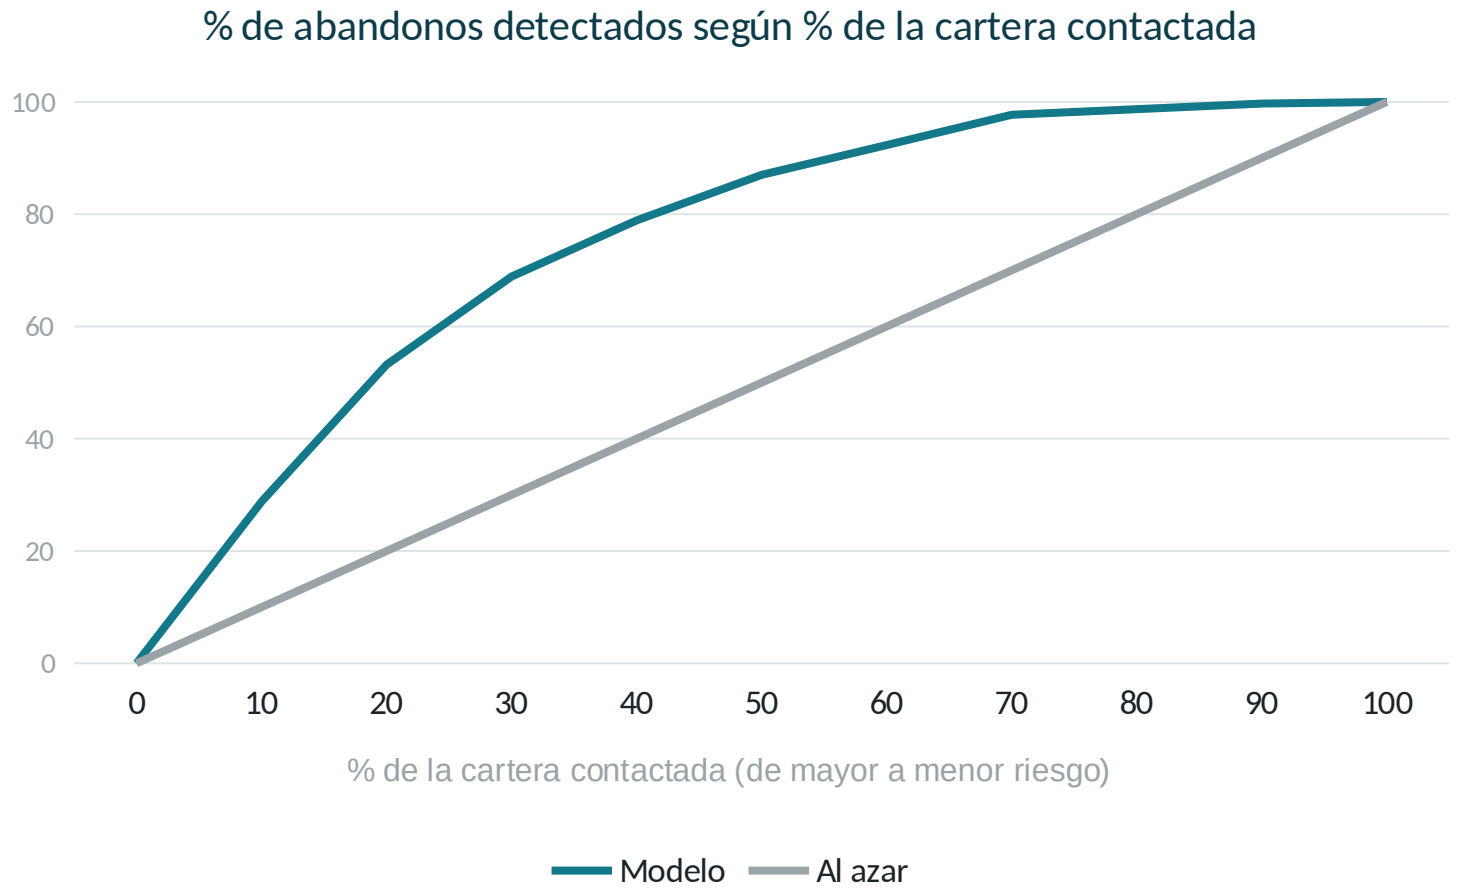
Ventajas extra
Explicable y con las probabilidades más confiables. SMOTE (solo en train) no mejoró.

Con el mismo cupo, detectamos 2,65 veces más abandonos

53 %

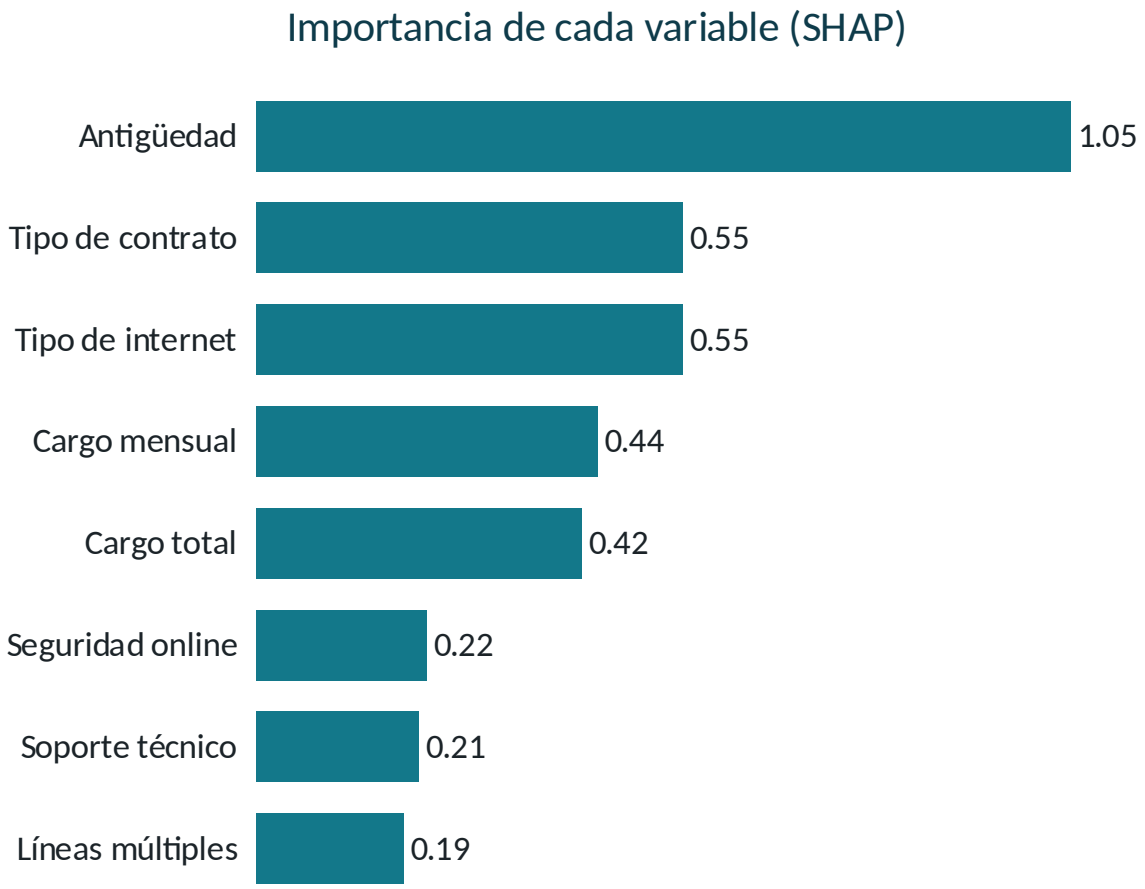
de los clientes que se van quedan dentro del 20 % que el modelo manda a llamar

Al azar: 20 %
Techo posible: 75 %



Meta fijada antes de entrenar: 55 % (mínimo 50 %). Se cumple el mínimo, no la meta.

Qué explica el riesgo según el modelo



1 **Los primeros meses son críticos**
En los primeros 6 meses abandona el 52 %; después de 4 años, el 10 %.

2 **El contrato mes a mes suma riesgo**
Un contrato de 2 años es el factor que más protege.

3 **Fibra óptica sin soporte técnico**
La fibra y la falta de soporte o seguridad online empujan el riesgo hacia arriba.

SHAP muestra cómo razona el modelo; no prueba causalidad.

Impacto: mismo presupuesto, más clientes retenidos

Por cada 10.000 clientes, frente a llamar al azar:

+879

abandonos detectados de más en cada campaña

+264

clientes retenidos esperados

USD 276 mil

más de beneficio neto anual

Supuestos para reemplazar con datos reales: USD 15 por contacto, 30 % de éxito de la acción de retención y 12 meses de facturación preservada. Con 15 % de éxito el beneficio del modelo es USD 181 mil; con 45 %, USD 604 mil.

Además automatiza la selección: hoy no hay criterio; con el modelo, la lista priorizada se genera en segundos antes de cada campaña.

Qué ofrecer a cada perfil de riesgo

1

Cliente nuevo con contrato mes a mes

Migración a contrato anual con beneficio de bienvenida.

2

Fibra óptica sin soporte ni seguridad

Soporte técnico o seguridad online sin costo por un período.

3

Pago con cheque electrónico

Incentivo para pasar a débito automático.

4

Score alto en cualquier perfil

Contacto proactivo de Retención antes del vencimiento.

Son hipótesis de negocio a validar en el piloto, no efectos causales probados.

Riesgos, ética y privacidad

1. **Datos sin fechas:** No sabemos si el patrón se mantiene en el tiempo: reentrenar y monitorear en cada campaña.

2. **Grupos menos detectados:** Clientes con personas a cargo: recall 24-34 % contra 55-58 %. Auditar por grupo en cada campaña.

3. **Atributos sensibles:** Sin género ni edad el modelo rinde igual (PR-AUC 0,664 vs. 0,666): se recomienda excluirlos.

4. **Privacidad:** Minimización de datos y control de accesos según la Ley 25.326 de Protección de Datos Personales.

En el test apareció una brecha de detección por género, pero no se repite en las 4.507 predicciones de validación cruzada: no es un patrón sistemático.

Recomendación: piloto A/B antes de escalar

1

Piloto

20 % priorizado por el modelo contra 20 % al azar, con el mismo presupuesto.

2

Medir

Retención real, costo por cliente retenido y detección por grupo.

3

Escalar

Solo si el piloto confirma el beneficio; reentrenar en cada campaña.

Código y datos: github.com/jgrozo660/Proyecto-Final-AnalisisDeDatos-UTN

Notebook en Colab: abrir desde el botón "Open in Colab" del README

Grupo 4 · ¡Gracias!