¿A quién llamar primero?

Predicción de abandono (churn) de clientes en una empresa de telecomunicaciones

Grupo 4

Agustín Bilche Braga · Agustina Díaz · Carlos Grozo · Milagros Crespo · Luana Zalcman

Diplomado en Ciencia de Datos y Análisis Avanzado · UTN.BA · Unidad 10 · Proyecto Final Integrador

Octubre de 2026

1 de cada 4 clientes se va, y no se puede llamar a todos

26,5 %

de los clientes abandona el servicio (tasa de churn observada en la muestra)

20 %

de la cartera puede contactar Retención en cada campaña

La pregunta de negocio

¿A qué 20 % llamar para detectar la mayor cantidad posible de clientes que se van a ir?

Hoy ese cupo se asigna sin un criterio. Llamando al azar se detecta, en promedio, solo el 20 % de los abandonos.

Cómo trabajamos: CRISP-DM

1

Negocio

KPI: % de abandonos detectados contactando al 20 %. Meta: 55 %.

2

Datos

5.634 clientes, 21 variables. EDA y control de calidad.

3

Preparación

Pipeline sin fuga de información; variable n_servicios.

4

Modelado

5 variantes comparadas con validación cruzada de 5 folds.

5

Evaluación

Test único de 1.127 clientes + intervalos de confianza.

6

Negocio otra vez

Impacto económico, auditoría ética y acciones.

Todo el proceso está en un notebook reproducible (Colab + GitHub) con semilla fija y un registro de decisiones.

Los datos: limpios a primera vista, con una trampa

5.634 clientes para entrenar y evaluar

1.409 clientes a predecir (test.csv)

21 variables: perfil, servicios, contrato y facturación

"0 valores nulos"... pero no

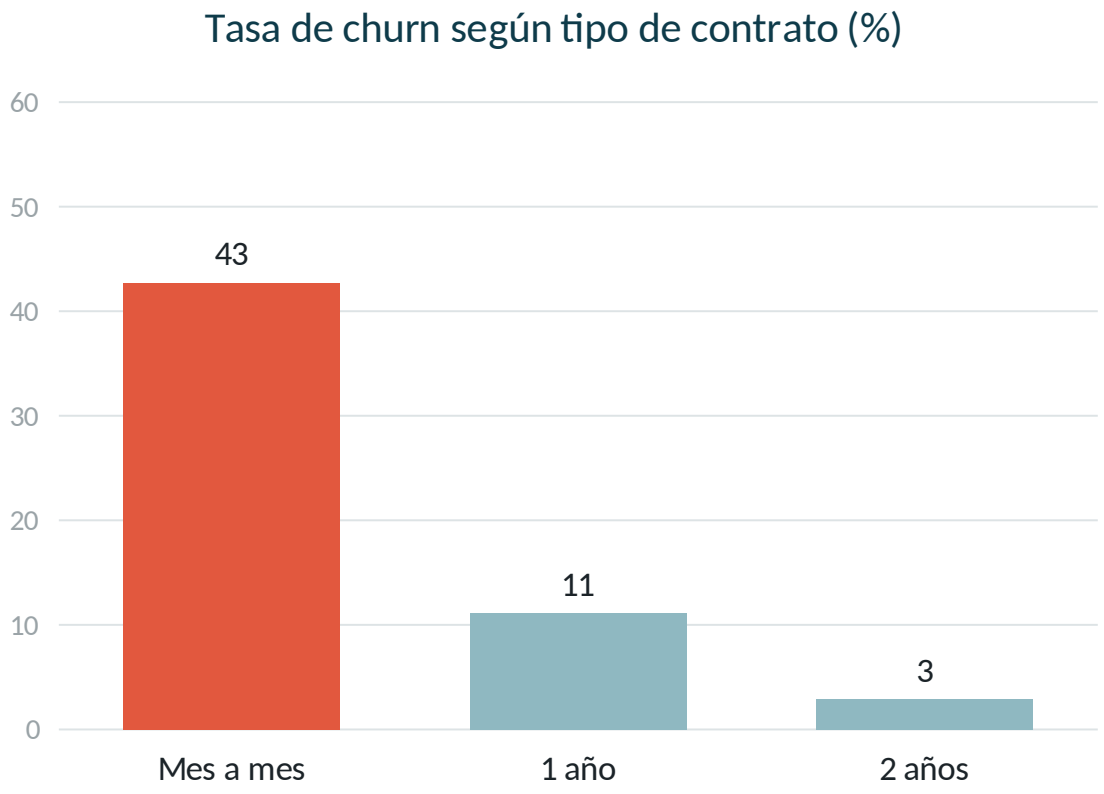
Los 8 clientes recién dados de alta (0 meses de antigüedad) tenían un cargo total de 1.397, que es exactamente la mediana de la columna: el archivo venía rellenado.

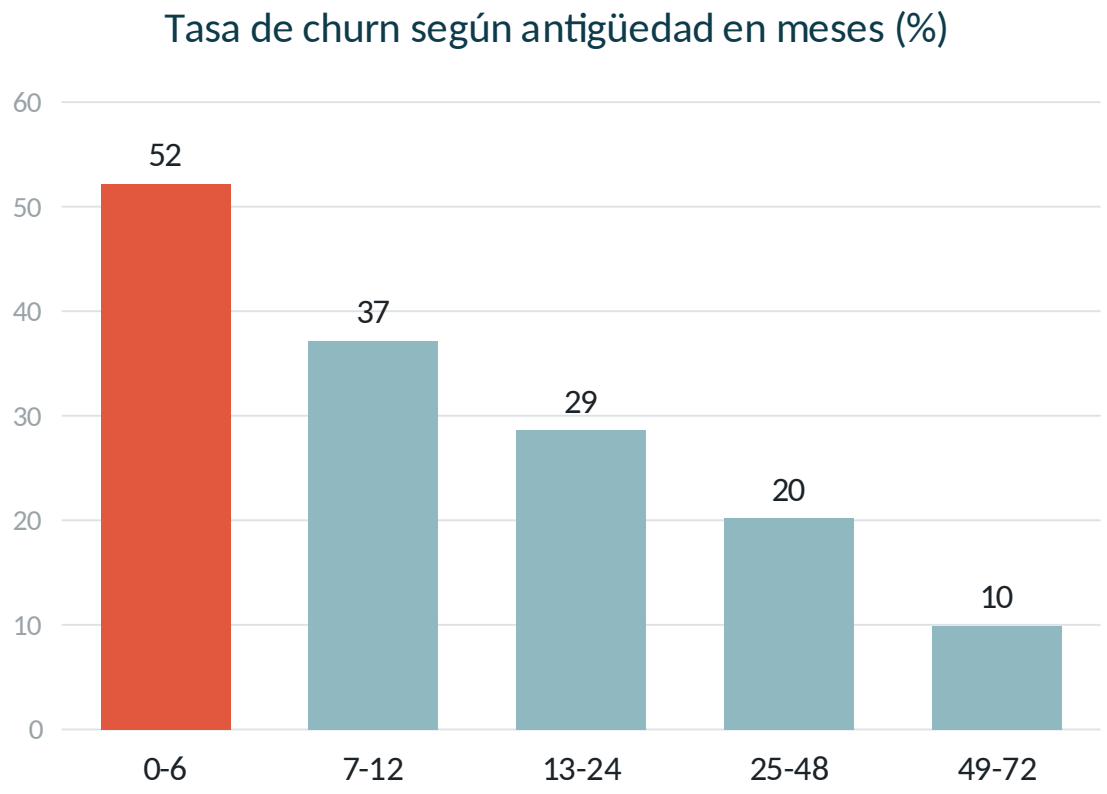
Decisión: corregirlo a 0.

Un cliente sin meses facturados no acumuló cargos. Además descartamos el "cargo promedio por mes" (repetía el cargo mensual) y agregamos la cantidad de servicios contratados.

Fuente: competencia de Kaggle "Predicción de fuga de cliente" (dataset Telco Customer Churn).

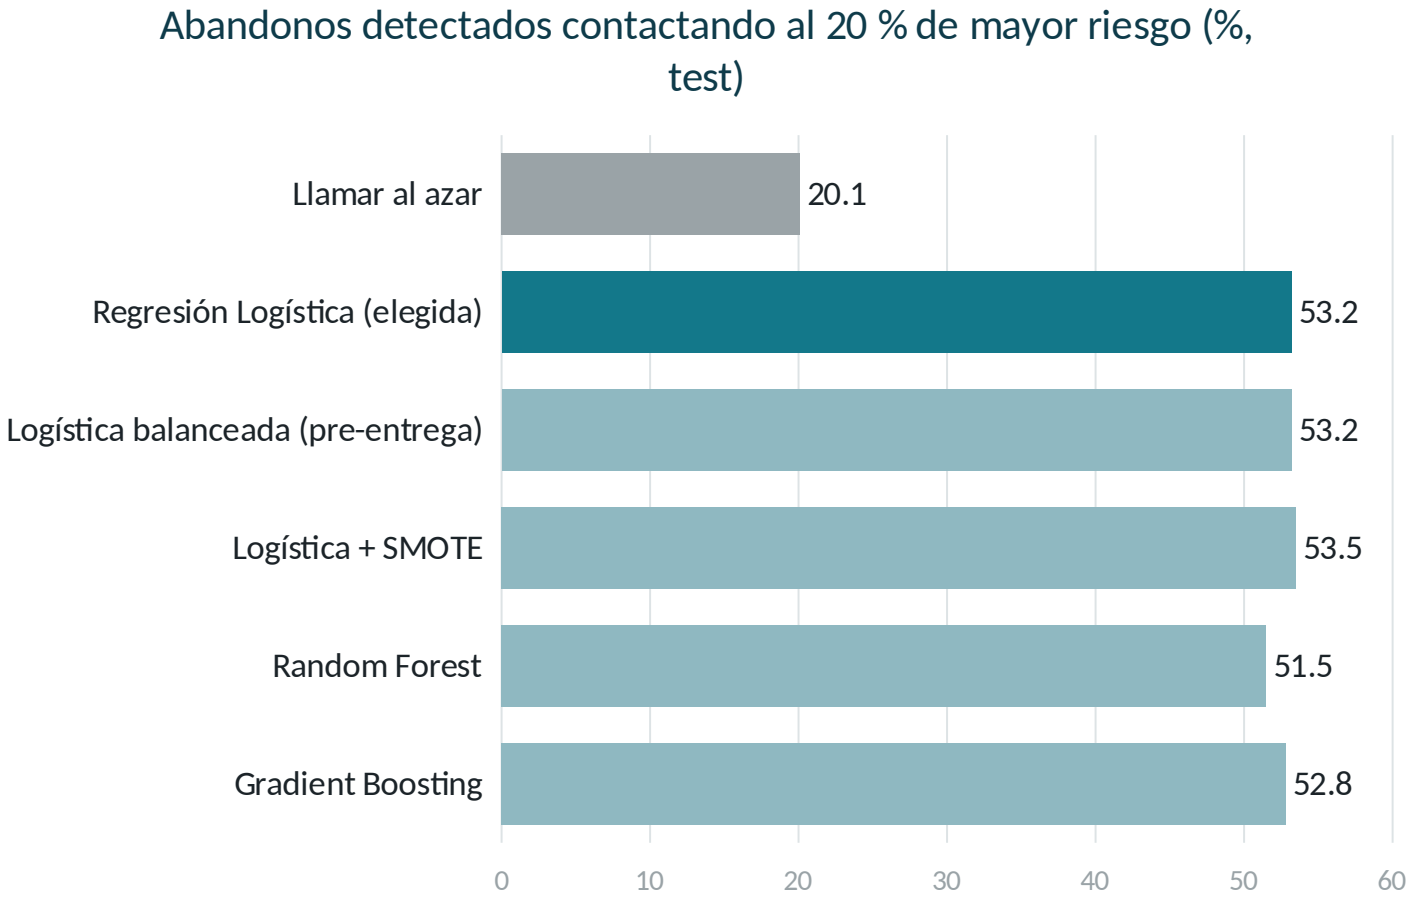
El abandono se concentra en clientes nuevos y sin compromiso





Contrato mes a mes: 43 % abandona, contra 3 % con contrato de 2 años. En los primeros 6 meses abandona más de la mitad. También suben el riesgo la fibra óptica, no tener soporte técnico y pagar con cheque electrónico.

Cinco modelos, un empate: elegimos el más simple



Empate estadístico
Los cinco quedan dentro del margen de error (validación cruzada e intervalos de confianza).

Regla fijada de antemano
Entre empatados, el más simple: Regresión Logística.

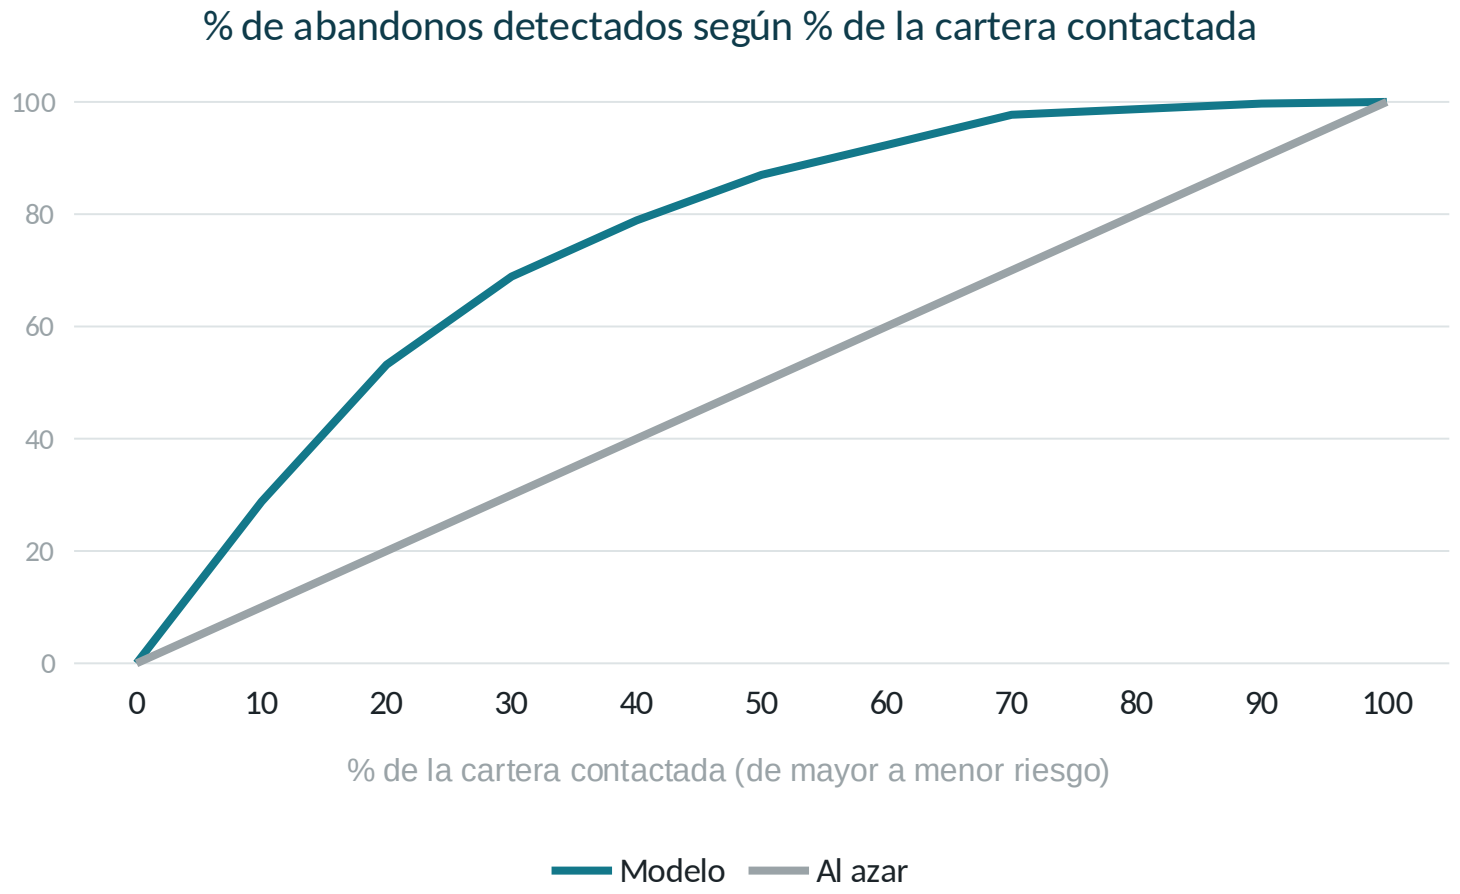
Ventajas extra
Explicable y con las probabilidades más confiables. SMOTE (solo en train) no mejoró.

Con el mismo cupo, detectamos 2,65 veces más abandonos

53 %

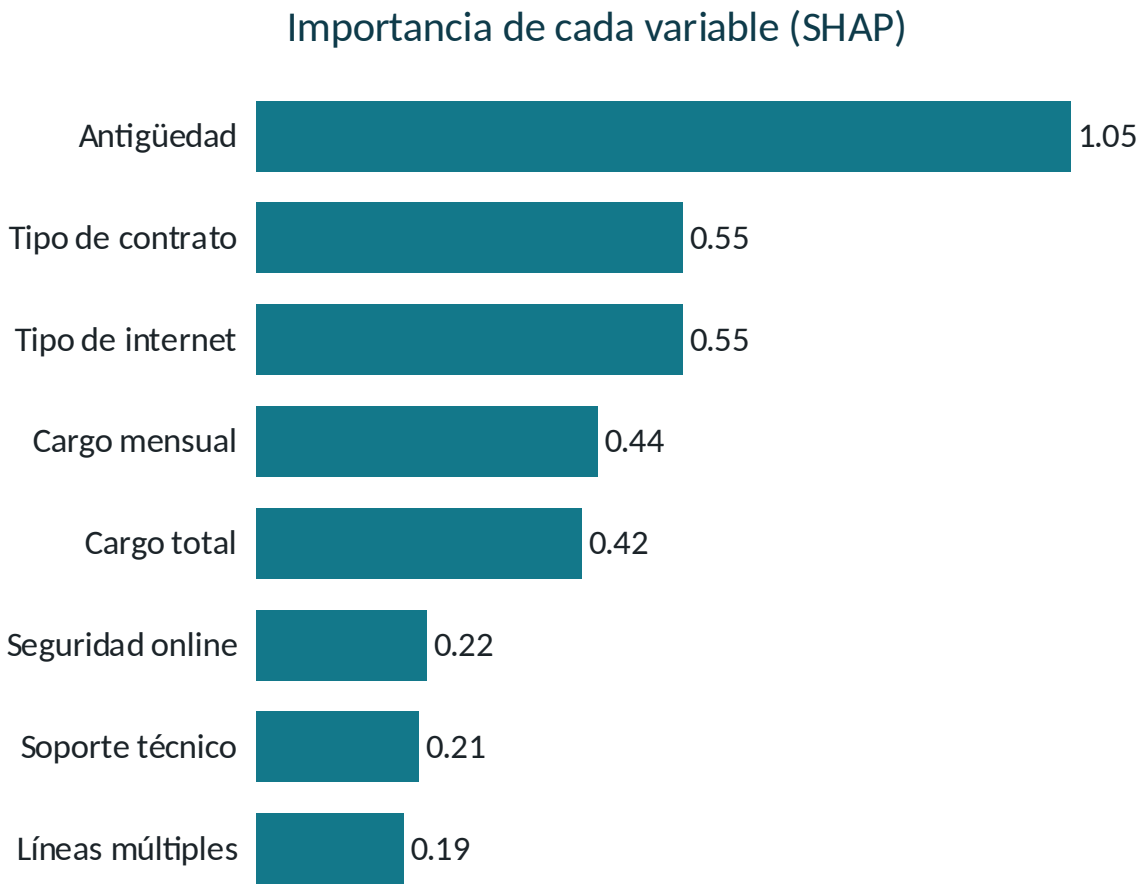
de los clientes que se van quedan dentro del 20 % que el modelo manda a llamar

Al azar: 20 %
Techo posible: 75 %



Meta fijada antes de entrenar: 55 % (mínimo 50 %). Se cumple el mínimo, no la meta.

Qué explica el riesgo según el modelo



1 **Los primeros meses son críticos**
En los primeros 6 meses abandona el 52 %; después de 4 años, el 10 %.

2 **El contrato mes a mes suma riesgo**
Un contrato de 2 años es el factor que más protege.

3 **Fibra óptica sin soporte técnico**
La fibra y la falta de soporte o seguridad online empujan el riesgo hacia arriba.

SHAP muestra cómo razona el modelo; no prueba causalidad.

Impacto: mismo presupuesto, más clientes retenidos

Por cada 10.000 clientes, frente a llamar al azar:

+879

abandonos detectados de más en cada campaña

+264

clientes retenidos esperados

USD 276 mil

más de beneficio neto anual

Supuestos para reemplazar con datos reales: USD 15 por contacto, 30 % de éxito de la acción de retención y 12 meses de facturación preservada. Con 15 % de éxito el beneficio del modelo es USD 181 mil; con 45 %, USD 604 mil.

Además automatiza la selección: hoy no hay criterio; con el modelo, la lista priorizada se genera en segundos antes de cada campaña.

Qué ofrecer a cada perfil de riesgo

1

Cliente nuevo con contrato mes a mes

Migración a contrato anual con beneficio de bienvenida.

2

Fibra óptica sin soporte ni seguridad

Soporte técnico o seguridad online sin costo por un período.

3

Pago con cheque electrónico

Incentivo para pasar a débito automático.

4

Score alto en cualquier perfil

Contacto proactivo de Retención antes del vencimiento.

Son hipótesis de negocio a validar en el piloto, no efectos causales probados.

Riesgos, ética y privacidad

1. **Datos sin fechas:** No sabemos si el patrón se mantiene en el tiempo: reentrenar y monitorear en cada campaña.

2. **Grupos menos detectados:** Clientes con personas a cargo: recall 24-34 % contra 55-58 %. Auditar por grupo en cada campaña.

3. **Atributos sensibles:** Sin género ni edad el modelo rinde igual (PR-AUC 0,664 vs. 0,666): se recomienda excluirlos.

4. **Privacidad:** Datos anonimizados, minimización de datos y control de accesos.

En el test apareció una brecha de detección por género, pero no se repite en las 4.507 predicciones de validación cruzada: no es un patrón sistemático.

Recomendación: piloto A/B antes de escalar

1

Piloto

20 % priorizado por el modelo contra 20 % al azar, con el mismo presupuesto.

2

Medir

Retención real, costo por cliente retenido y detección por grupo.

3

Escalar

Solo si el piloto confirma el beneficio; reentrenar en cada campaña.

Código y datos: github.com/jgrozo660/Proyecto-Final-AnalisisDeDatos-UTN

Notebook en Colab: abrir desde el botón "Open in Colab" del README

Grupo 4 · ¡Gracias!